

MÁSTER UNIVERSITARIO EN LÓGICA, COMPUTACIÓN E INTELIGENCIA ARTIFICIAL (MULCIA)
 PROCESAMIENTO DEL LENGUAJE NATURAL · CURSO 2025–26

Ejemplo ilustrativo del Proyecto Longitudinal

Sistema de análisis de reseñas en e-commerce multilingüe

Cómo usar este documento. Este documento muestra cómo podría desarrollarse el Proyecto Longitudinal aplicado al dominio del análisis de reseñas en plataformas de e-commerce multilingüe. Cubre las tres entregas del TDT más las notas sobre la PoC.

Léelo prestando atención a *cómo se razona y se justifica cada decisión*, no a *qué se decide*. Tu proyecto trabajará sobre un dominio diferente, pero el tipo de análisis, el nivel de detalle y la forma de argumentar deben ser comparables a los que ves aquí.

Las **cajas «Nota para el alumno»** no forman parte del TDT: explican el razonamiento detrás de cada sección para ayudarte a trasladar el enfoque a tu propio dominio. En tu entrega, esas cajas no deben aparecer.

Índice

1. Justificación del dominio	Antonio	3
2. Caracterización lingüística del problema	Óscar y Nicolás	3
2.1. Ambigüedad en múltiples niveles		3
2.2. Fenómenos específicos del género textual		4
2.3. Complejidad multilingüe		4
3. Descomposición en tareas PLN	Elsa	4
4. Restricciones no técnicas	¿Cuáles son? xd	5
5. Hipótesis de diseño inicial	Todos	6
6. Revisiones respecto a la Entrega 1		7
7. Decisiones de representación y modelado		7
7.1. Representación textual		7
7.2. Selección de modelo para T2 (tarea principal de la PoC)		8
8. Datos y protocolo de evaluación		9
8.1. Dataset seleccionado para la PoC		9
8.2. Métricas y criterio de éxito		9
9. Arquitectura final del sistema		10
10. Implementación		11
11. Evaluación y resultados		11

12. Análisis de errores	12
13. Reflexión crítica	13
13.1. Brecha entre la PoC y un sistema en producción	13
13.2. ¿Qué habría decidido el grupo de forma diferente?	13

Entrega 1 — Análisis y diseño inicial

1. Justificación del dominio

Las plataformas de e-commerce acumulan decenas de millones de reseñas de usuarios en múltiples idiomas. Estas reseñas son el principal factor de decisión de compra para los usuarios y una fuente crítica de inteligencia de producto para los vendedores. Su gestión manual resulta inviable a la escala actual, y los enfoques basados únicamente en la valoración numérica (estrellas) ignoran el contenido textual, que es considerablemente más informativo.

Las soluciones existentes en el mercado presentan limitaciones claras: se limitan al análisis de sentimiento global (positivo/negativo/neutro), no distinguen entre aspectos del producto, tienen dificultades con el multilingüismo más allá de los idiomas mayoritarios y producen salidas poco explicables. Existe por tanto un espacio para un sistema que aborde estas limitaciones de forma integrada.

El dominio es especialmente adecuado para PLN por varias razones: alta variabilidad lingüística (múltiples idiomas, registros, errores ortográficos, emojis), riqueza semántica estructurada (opiniones simultáneas sobre múltiples aspectos de un producto), problema de autenticidad (una fracción de reseñas son fraudulentas, con patrones lingüísticos detectables) e impacto económico directo y medible.

Nota para el alumno

La justificación del dominio no es un trámite. Debe responder a dos preguntas concretas: (1) ¿por qué este problema requiere PLN y no otra solución más sencilla? y (2) ¿qué dejan sin resolver las soluciones actuales? Un párrafo genérico sobre «el crecimiento del e-commerce» sin responder a estas dos preguntas no es una justificación adecuada.

2. Caracterización lingüística del problema

Antes de plantear cualquier solución técnica es imprescindible entender qué propiedades del lenguaje natural hacen este dominio difícil para el procesamiento automático.

2.1. Ambigüedad en múltiples niveles

El lenguaje de las reseñas presenta ambigüedad en prácticamente todos los niveles de análisis lingüístico:

- **Nivel léxico.** «La batería dura poco» puede significar que la batería tiene poca duración (negativo) o que el proceso de carga dura poco tiempo (positivo). El adjetivo «original» puede referirse a la autenticidad del producto o a su carácter innovador.
- **Nivel sintáctico.** Las reseñas contienen frecuentemente oraciones elípticas («Muy buena relación calidad-precio, el envío fatal») en las que la ausencia de sujeto explícito obliga a inferir el referente del predicado.

- **Nivel semántico.** La ironía y el sarcasmo son habituales: «Qué maravilla, llegó con tres semanas de retraso y roto» tiene polaridad opuesta a su contenido literal. Los modelos que trabajan con la hipótesis distribucional tienen dificultades estructurales con estos casos.
- **Nivel pragmático.** La misma expresión valorativa tiene significado distinto según el historial del usuario: «como siempre» puede ser un elogio o una queja crónica dependiendo del contexto conversacional.

2.2. Fenómenos específicos del género textual

Las reseñas de e-commerce constituyen un género textual con características propias:

- **Fórmulas convencionales de valoración** («muy satisfecho con la compra», «lo recomiendo totalmente») que pueden ser auténticas o indicadores de reseñas incentivadas.
- **Referencias temporales al proceso de compra** («tardó en llegar», «a los dos meses se rompió») que introducen dependencias temporales irrelevantes para el análisis de sentimiento del producto en sí.
- **Arbitrariedad del signo valorativo según el dominio:** «ligero» es positivo para un portátil pero negativo para una maleta de viaje resistente.

2.3. Complejidad multilingüe

El multilingüismo añade una capa de complejidad que va más allá de procesar varios idiomas por separado:

- *Code-switching* intrafrase: «El display es increíble pero el lag es insoportable».
- Variación dialectal intralingüística con diferencias en léxico valorativo entre el español peninsular y el latinoamericano.
- Distribución muy desequilibrada de recursos lingüísticos: los léxicos de sentimiento, los datos etiquetados y los modelos preentrenados están masivamente sesgados hacia el inglés.

Nota para el alumno

Esta sección es el núcleo de la Entrega 1 y donde más se diferencia un análisis maduro de uno superficial. Hay que evitar dos errores frecuentes: (1) describir los fenómenos lingüísticos de forma genérica sin anclarlos al dominio concreto («el lenguaje es ambiguo» no es un análisis), y (2) enumerar características del dominio sin explicar por qué son difíciles para un sistema automático. Lo que se evalúa es la capacidad de ver el dominio con ojos tanto lingüísticos como computacionales: ¿qué haría que un hablante nativo tuviera dudas al interpretar este texto?, pero también ¿qué hace que esa duda sea especialmente difícil de resolver para un modelo? Ambas perspectivas son necesarias.

3. Descomposición en tareas PLN

El análisis lingüístico previo revela que el sistema debe abordar cuatro tareas diferenciadas, con distintos requisitos técnicos y distintas prioridades de negocio:

Tarea	Descripción	Prioridad
T1: Identificación de idioma	Detección del idioma principal de la reseña. Tarea habilitadora para el resto.	Alta
T2: Sentimiento global	Clasificación de la polaridad general (positivo / negativo / neutro).	Alta
T3: Análisis por aspecto (ABSA)	Identificación de aspectos mencionados (calidad, precio, envío, atención) y polaridad de cada uno.	Alta
T4: Detección de autenticidad	Identificación de reseñas fraudulentas o inventadas mediante señales lingüísticas.	Muy alta

Las tareas no son independientes: T1 habilita T2, T3 y T4. T4 debe ejecutarse antes de T2 y T3 para no contaminar el análisis con reseñas fraudulentas. Este orden de dependencias tiene implicaciones directas en la arquitectura del sistema.

Desde la perspectiva de la arquitectura tecnológica del Capítulo 2, T1 opera al nivel de preprocesamiento fundamental; T2 y T4 son tareas de clasificación textual; T3 es una tarea de extracción de información estructurada de mayor complejidad.

Nota para el alumno

La descomposición en tareas no debe hacerse enumerando todo lo que podría hacer el sistema, sino identificando las tareas mínimas necesarias para el objetivo descrito. Hay que justificar por qué cada tarea es necesaria y cuál es su relación de dependencia con las demás: esto es lo que convierte la lista en una arquitectura, y no en un catálogo de funcionalidades.

4. Restricciones no técnicas

El análisis de los actores implicados revela un conjunto de restricciones que deben incorporarse como criterios de diseño desde el principio:

- **Explicabilidad.** Las decisiones de moderación (especialmente T4) deben ser justificables ante vendedores y, en contextos regulatorios europeos, ante autoridades de protección al consumidor. Esto impone restricciones sobre la opacidad de los modelos.
- **RGPD y privacidad.** Las reseñas contienen datos de usuarios europeos. El sistema debe asegurar que los datos de entrenamiento estén correctamente anonimizados y que no se almacenen datos personales innecesariamente en la pipeline de inferencia.
- **Sesgo lingüístico y cultural.** Un sistema entrenado predominantemente con reseñas en inglés tendrá peor rendimiento en otros idiomas e introducirá sesgos sistemáticos contra usuarios de mercados no anglosajones. Esto debe medirse explícitamente.
- **Latencia.** T1 y T2 deben operar a baja latencia (objetivo: <200 ms por reseña) para no impactar la experiencia de usuario en tiempo real. T3 y T4 pueden ejecutarse en diferido.
- **Falsos positivos en detección de fraude.** Penalizar erróneamente a un vendedor legí-

timo tiene consecuencias graves para la confianza en la plataforma. La precisión en T4 es crítica.

Nota para el alumno

Las restricciones no técnicas no son adornos al final de la sección: son criterios de diseño que deben reaparecer en las entregas siguientes condicionando las decisiones de modelado. Si en la Entrega 2 el grupo elige un modelo por su precisión ignorando los requisitos de explicabilidad o de latencia que identificó aquí, hay una incoherencia que el profesorado detectará y que reducirá la valoración de la coherencia acumulativa del TDT.

5. Hipótesis de diseño inicial

Con el análisis lingüístico y el mapa de restricciones establecidos, formulamos hipótesis iniciales sobre el enfoque técnico más adecuado para cada tarea. Estas hipótesis son deliberadamente provisionales y se revisarán en la Entrega 2.

- **T1 (identificación de idioma):** Paradigma estadístico. Los modelos de n-gramas de caracteres (fastText-LID, langdetect) alcanzan alta precisión con latencia mínima. No hay motivación para mayor complejidad.
- **T2 (sentimiento global):** Paradigma estadístico o neuronal. Un modelo TF-IDF con clasificador clásico puede ser una línea base sólida. Para el contexto multilingüe, probablemente se necesite un modelo preentrenado multilingüe, pero la decisión depende del tamaño del corpus disponible.
- **T3 (ABSA):** Paradigma neuronal. La identificación simultánea de aspectos y polaridades requiere capturar dependencias contextuales complejas. Los modelos Transformer parecen la arquitectura más prometedora, aunque habrá que evaluar el coste computacional frente al requisito de latencia.
- **T4 (detección de fraude):** Paradigma híbrido. Las señales lingüísticas pueden capturar-se con modelos estadísticos, pero la detección robusta probablemente requiera combinar señales textuales con señales de comportamiento del usuario (patrón temporal, diversidad de productos). Esta combinación introduce complejidad de integración que conviene analizar.

Nota para el alumno

Las hipótesis iniciales no son el lugar donde se demuestra que el grupo ya sabe la respuesta: son el punto de partida del razonamiento. Es completamente aceptable —y esperable— que en la Entrega 2 algunas de estas hipótesis se revisen o contradigan. Lo que se evalúa es la solidez del argumento en cada momento, no haber acertado desde el principio.

Entrega 2 — Diseño revisado

6. Revisiones respecto a la Entrega 1

Tras estudiar los modelos estadísticos (Capítulo 3), los modelos vectoriales (Capítulo 4) y los modelos neuronales (Capítulo 5), revisamos las hipótesis iniciales:

- **T1 se mantiene.** Los modelos de n-gramas de caracteres siguen siendo la solución más eficiente para la identificación de idioma. El estudio de la ley de Zipf (Capítulo 3) confirma que los patrones de frecuencia de caracteres son señales muy robustas para esta tarea, incluso con vocabulario especializado.
- **T2 se matiza.** El análisis de las limitaciones del paradigma vectorial (Capítulo 4) confirma que TF-IDF es una línea base sólida pero insuficiente para el contexto multilingüe y para reseñas con ironía. Se confirma la necesidad de un modelo preentrenado multilingüe, aunque con una restricción nueva: los requisitos de RGPD desaconsejan el uso de APIs externas. La solución debe desplegarse internamente.
- **T3 se confirma y se concreta.** Los embeddings contextuales (Capítulo 5) son esenciales para ABSA: la misma palabra tiene polaridad diferente en función del aspecto al que acompaña, y esto requiere representación dependiente del contexto. XLM-RoBERTa con cabeza de clasificación de aspectos es el candidato más adecuado.
- **T4 se simplifica para la PoC.** El componente de señales de comportamiento requiere datos de usuario que no están disponibles en datasets públicos. La PoC se limitará a las señales lingüísticas de autenticidad, con el entendimiento explícito de que un sistema en producción requeriría el componente híbrido descrito en la Entrega 1.

Nota para el alumno

La sección de revisiones es obligatoria desde la Entrega 2 y es una de las que mejor refleja la madurez del razonamiento del grupo. Dos señales de alarma que el profesorado detecta fácilmente: (1) ausencia total de revisiones —indica que el grupo no ha integrado los nuevos contenidos del curso—, y (2) revisiones que solo confirman todo lo anterior —sugiere que las hipótesis iniciales fueron formuladas ya con la respuesta en mente, lo que vacía de sentido el ejercicio.

7. Decisiones de representación y modelado

7.1. Representación textual

La elección de representación no es única: distintas tareas tienen distintos requisitos.

Tarea	Representación elegida	Justificación
T1	N-gramas de caracteres	Robusta ante errores ortográficos y préstamos. Suficiente para la tarea. Latencia mínima.
T2	TF-IDF (línea base) + embeddings contextuales (sistema)	TF-IDF es interpretable y eficiente como referencia. Los embeddings contextuales resuelven el problema de la ironía y la negación que TF-IDF no puede capturar.
T3	Embeddings contextuales	La relación aspecto-polaridad es intrínsecamente contextual. Un embedding estático de «bueno» no distingue si califica la calidad o el precio.
T4	TF-IDF con features adicionales	Las señales léxicas de autenticidad (exceso de superlativos, ausencia de especificidad) son capturables con TF-IDF. La interpretabilidad es importante para la explicabilidad requerida.

7.2. Selección de modelo para T2 (tarea principal de la PoC)

Se comparan dos candidatos para la tarea de sentimiento global, que es la que se implementará en la PoC:

Candidato A: TF-IDF + SVM. Alta interpretabilidad (los pesos del vector de soporte permiten identificar las features más relevantes), eficiente computacionalmente, históricamente el clasificador de texto de mayor rendimiento en el paradigma vectorial clásico. Limitación principal: no captura contexto ni maneja la negación de forma natural. Adecuado como línea base obligatoria.

Candidato B: XLM-RoBERTa-base con fine-tuning. Modelo preentrenado en 100 idiomas, rendimiento de estado del arte en clasificación de sentimiento multilingüe. Resuelve los problemas de ironía y negación de TF-IDF. Desventajas: coste computacional mayor (re-

quiere GPU para latencias razonables a escala), menor interpretabilidad, necesita corpus de fine-tuning suficientemente grande. Compatible con el requisito de despliegue interno.

La PoC implementará ambos y comparará su rendimiento bajo las mismas condiciones de evaluación, lo que permitirá cuantificar el coste-beneficio del enfoque neuronal para este dominio concreto.

Nota para el alumno

La decisión de representación y modelo debe justificarse en relación con las restricciones identificadas en la Entrega 1, no de forma genérica. Un grupo que elige XLM-RoBERTa «porque es el estado del arte» sin conectarlo con los requisitos de multilingüismo, RGPD y latencia de su dominio concreto no está razonando como ingeniero: está eligiendo por inercia. Al contrario, un grupo que argumenta que TF-IDF es suficiente para su dominio porque sus textos son cortos, formales y en un único idioma bien representado también puede tener razón, si el argumento está bien construido.

8. Datos y protocolo de evaluación

8.1. Dataset seleccionado para la PoC

Se utilizará el *Multilingual Amazon Reviews Corpus* (Keung et al., 2020), disponible en HuggingFace Datasets. Contiene reseñas en inglés, alemán, francés, japonés, chino y español, con valoración en estrellas que permite construir etiquetas de sentimiento. Se usarán los *splits* oficiales de train/dev/test para garantizar la reproducibilidad.

Sesgos identificados: La distribución de clases está desequilibrada (más reseñas de 5 estrellas que de 1 o 2). Se aplicará un muestreo estratificado para construir un conjunto de entrenamiento balanceado. El corpus está sesgado hacia productos de electrónica y libros; el rendimiento en otras categorías puede ser inferior y debe medirse de forma separada.

8.2. Métricas y criterio de éxito

Se reportará *accuracy* y F1-macro sobre el conjunto de prueba. El F1-macro es más informativo que la *accuracy* en presencia del desbalance de clases. Los resultados se desglosan por idioma para detectar degradaciones en lenguas con menos datos de entrenamiento.

Como referencia mínima, se incluirá siempre el rendimiento de un clasificador de clase mayoritaria. Cualquier modelo propuesto debe superar este umbral de forma clara.

El criterio de éxito para la PoC no es alcanzar el estado del arte, sino: (1) superar significativamente la línea base trivial, (2) mostrar que XLM-RoBERTa mejora sobre TF-IDF+SVM de forma consistente entre idiomas, y (3) identificar en qué tipos de reseña el modelo falla y conectar esos fallos con el análisis lingüístico de la Entrega 1.

Nota para el alumno

El protocolo de evaluación debe diseñarse para responder una pregunta concreta del dominio, no para maximizar una métrica abstracta. En este caso, la pregunta es: «¿merece la pena la complejidad adicional del modelo neuronal para este dominio multilingüe?»

Esa pregunta exige la comparación con la línea base y el desglose por idioma. En tu propio dominio, identifica primero qué pregunta quieres responder con la evaluación y diseña el protocolo a partir de ahí.

9. Arquitectura final del sistema

El sistema se organiza en cuatro componentes con el siguiente flujo de procesamiento:

1. **C1 — Identificador de idioma** (fastText-LID): recibe el texto de la reseña y determina el idioma. Si el idioma no está cubierto por los modelos disponibles, la reseña se enruta a revisión manual.
2. **C2 — Clasificador de sentimiento global** (XLM-RoBERTa-base con fine-tuning): opera en tiempo real (<200 ms). Produce la polaridad global de la reseña.
3. **C3 — Analizador de aspectos** (XLM-RoBERTa-large con cabeza ABSA): opera en diferido. Produce una lista de pares (aspecto, polaridad) para cada reseña que supera el filtro de C4.
4. **C4 — Detector de autenticidad** (TF-IDF + SVM con features léxicas): opera en diferido. Las reseñas marcadas como potencialmente fraudulentas se retienen para revisión humana con una explicación basada en las features más relevantes.

El diagrama de flujo refleja la dependencia $T1 \rightarrow \{T2, T4\} \rightarrow T3$: C1 precede a todos los demás; C4 debe ejecutarse antes de que los resultados de C2 y C3 sean publicados para usuarios y vendedores.

Nota para el alumno

El diagrama de arquitectura es obligatorio en la Entrega 2. No hace falta que sea elaborado gráficamente: un diagrama claro en texto (o exportado desde cualquier herramienta de diagramas) es suficiente. Lo importante es que refleje los componentes, las dependencias entre ellos y los flujos de datos, de forma que un lector externo pueda entender cómo funciona el sistema sin necesidad de explicaciones adicionales.

Entrega 3 — Prueba de concepto y reflexión

Implementación, evaluación y análisis crítico

Nota sobre esta entrega en el ejemplo ilustrativo. A diferencia de las entregas anteriores, la Entrega 3 no se desarrolla aquí con la misma extensión porque hacerlo implicaría proporcionar código y resultados concretos que podrían ser copiados directamente. En su lugar, se describen con detalle los componentes del informe que debe acompañar a la PoC, con el razonamiento detrás de cada uno. El repositorio de código de un grupo real completaría este documento con la implementación.

10. Implementación

La PoC implementa el clasificador de sentimiento global (C2) sobre el *Multilingual Amazon Reviews Corpus*, comparando los dos candidatos identificados en la Entrega 2: TF-IDF+SVM y XLM-RoBERTa-base con fine-tuning.

El *pipeline* cubre: carga y partición de datos respetando los *splits* oficiales, preprocesamiento (tokenización con el tokenizador nativo de cada modelo; para TF-IDF, eliminación de stop-words preservando negaciones), representación, entrenamiento y evaluación. El repositorio incluye un README con instrucciones de reproducción, versiones de dependencias y tiempo estimado de ejecución en CPU y GPU.

La elección de implementar C2 y no C3 o C4 responde a tres criterios: (1) es el componente central del sistema, sin el cual los demás carecen de utilidad; (2) permite una comparación directa entre el paradigma estadístico y el neuronal, que es la pregunta de diseño más relevante identificada en la Entrega 2; y (3) el dataset disponible tiene las etiquetas necesarias para entrenarlo y evaluarlo de forma rigurosa.

Nota para el alumno

La justificación del componente elegido para la PoC es parte de la evaluación. No vale «hemos implementado esto porque era lo más fácil» ni «hemos implementado el modelo más avanzado para demostrar que podemos». El criterio debe ser: ¿qué componente demuestra mejor la viabilidad del sistema y responde a la pregunta de diseño más relevante del TDT?

11. Evaluación y resultados

Los resultados se presentan sobre el conjunto de prueba oficial, desglosados por idioma y por clase. Se incluye siempre el clasificador de clase mayoritaria como referencia mínima.

Los resultados ilustrativos que cabría esperar en este dominio son: TF-IDF+SVM alrededor de 0.72–0.76 de F1-macro en inglés, con degradación notable en idiomas con menos datos; XLM-RoBERTa-base alrededor de 0.83–0.87 de F1-macro en inglés con degradación menor entre idiomas. La comparación confirmaría la hipótesis de la Entrega 2: el coste computacional

adicional del modelo neuronal se justifica para un sistema multilingüe real.

Nota para el alumno

Los resultados numéricos son una condición necesaria pero no suficiente de la Entrega 3. Lo que diferencia un informe de calidad es lo que viene después: el análisis de errores y la reflexión crítica. Un grupo que reporta un F1 de 0.85 sin analizar en qué casos falla el modelo habrá aprendido menos que uno que reporta un F1 de 0.72 con un análisis detallado de por qué falla y qué revelan esos fallos sobre el dominio.

12. Análisis de errores

El análisis cualitativo de los errores del modelo revela tres patrones sistemáticos, cada uno con su explicación lingüística conectada con la Entrega 1:

Patrón 1: Fallos en reseñas con ironía y sarcasmo. El modelo clasifica erróneamente reseñas cuya polaridad literal es opuesta a la intención comunicativa («Genial, el producto llegó en piezas»). Este patrón confirma la dificultad identificada en la sección 2.1 sobre ambigüedad semántica. La frecuencia de este patrón es mayor en español e italiano que en inglés, posiblemente porque el corpus de preentrenamiento de XLM-RoBERTa contiene más ejemplos irónicos en inglés.

Patrón 2: Confusión en reseñas con polaridad mixta. Reseñas que contienen opiniones positivas y negativas sobre distintos aspectos del producto (calidad positiva, envío negativo) son clasificadas de forma inconsistente. Esto no es un fallo del modelo T2 sino una evidencia de que la tarea T3 (ABSA) es necesaria: el sentimiento global es una simplificación que no captura la riqueza informativa de estas reseñas.

Patrón 3: Degradación en idiomas con vocabulario especializado de nicho. El modelo falla con mayor frecuencia en reseñas de productos técnicos con vocabulario muy especializado en idiomas distintos del inglés. Esto conecta con el análisis de la dispersión de datos del Capítulo 3: los términos técnicos de nicho tienen frecuencias muy bajas en el corpus de preentrenamiento para lenguas no mayoritarias, y el modelo no ha aprendido sus propiedades semánticas de forma confiable.

Nota para el alumno

Cada patrón de error debe conectar con el análisis lingüístico de la Entrega 1. Si en la Entrega 1 identificaste un fenómeno lingüístico difícil (ironía, polaridad mixta, variación dialectal) y en la Entrega 3 el modelo falla exactamente en esos casos, eso es un resultado valioso: confirma que tu análisis inicial era correcto y que el problema era genuinamente difícil. Si el modelo falla en casos que no anticipaste, eso también es valioso: amplía tu comprensión del dominio. En ningún caso los errores son un «problema» que hay que minimizar en el informe.

13. Reflexión crítica

13.1. Brecha entre la PoC y un sistema en producción

La PoC demuestra la viabilidad del componente central del sistema, pero deja fuera elementos que serían imprescindibles en producción:

- El componente C4 de detección de autenticidad no está implementado. En producción, la ausencia de este filtro contaminaría el análisis de sentimiento con reseñas fraudulentas, degradando la calidad de las señales para vendedores y usuarios.
- El sistema no incluye el módulo de explicabilidad requerido por las restricciones identificadas en la Entrega 1. Añadir LIME o SHAP sobre el modelo XLM-RoBERTa supone un coste computacional adicional que no se ha evaluado.
- La latencia del modelo neuronal en CPU está en torno a 800 ms por reseña, cuatro veces por encima del objetivo de 200 ms establecido en la Entrega 1. En producción sería necesario cuantización INT8 o destilación del modelo para cumplir el SLA.

13.2. ¿Qué habría decidido el grupo de forma diferente?

Tras implementar la PoC, identificamos tres decisiones que revisaríamos:

En primer lugar, el alcance de la Entrega 2 fue demasiado ambicioso al plantear cuatro tareas. Con el tiempo disponible, habría sido más honesto focalizar el diseño en T1 y T2 desde el principio, y tratar T3 y T4 como extensiones futuras en lugar de componentes del sistema principal.

En segundo lugar, el análisis de datos de la Entrega 2 no anticipó el impacto real del desbalance de clases en el rendimiento sobre reseñas de 2 y 4 estrellas, que son las más difíciles de clasificar. Un análisis exploratorio más detallado del corpus habría llevado a diseñar el protocolo de evaluación de forma diferente.

En tercer lugar, la decisión de comparar TF-IDF+SVM con XLM-RoBERTa-base fue correcta, pero habría añadido valor comparar también con FastText, que es un punto intermedio entre ambos extremos en términos de coste computacional y rendimiento multilingüe.

Nota para el alumno

La reflexión crítica es la sección más difícil de escribir bien porque requiere honestidad intelectual: identificar los errores propios con precisión, sin minimizarlos ni exagerarlos. Pero no se reduce a listar fallos. Tiene dos objetivos complementarios: (1) analizar la brecha entre la PoC y un sistema en producción real —qué necesidades, dificultades, riesgos y requisitos quedan fuera del prototipo—, y (2) revisar retrospectivamente las decisiones de diseño: qué se cambiaría y por qué. Una reflexión que dice «todo salió como esperábamos» es poco creíble. Una que lista fallos sin analizar sus causas ni conectarlos con las restricciones identificadas en la Entrega 1 es superficial.