

Asistente de preguntas frecuentes

Proyecto longitudinal de diseño de sistemas PLN

Antonio Macías Ferrera, Elsa Domínguez González, Óscar Niño Robles

Nicolás Rodríguez Ruiz

Máster Universitario en Lógica, Computación e Inteligencia Artificial
Universidad de Sevilla

Índice

1. Justificación del dominio	3
2. Caracterización lingüística	4
2.1. Ambigüedad en múltiples niveles	4
2.2. Fenómenos específicos del género textual	4
2.3. Complejidad multilingüe	5
3. Descomposición en tareas PLN	6
4. Restricciones no técnicas	7
5. Hipótesis de diseño inicial	7
6. Revisiones respecto a la Entrega 1	9
7. Decisiones de representación y modelado	10
7.1. Representación textual	10
7.2. Selección de modelos	11
8. Datos y protocolo de evaluación	12
8.1. <i>Dataset</i> seleccionado para la PoC	12
8.2. Métricas y criterio de éxito	13
9. Arquitectura final del sistema	14
10. Implementación	17
11. Evaluación y resultados	19
12. Análisis de errores	20

13. Reflexión crítica**21**

Entrega 1 — Análisis y diseño inicial

1. Justificación del dominio

El creciente proceso de digitalización y globalización empresarial ha transformado la gestión de la atención al cliente hacia un modelo descentralizado, externalizado y digital. Sin embargo, las tendencias actuales en este ámbito no hacen más que ampliar la brecha entre grandes organizaciones y pequeñas empresas. Las grandes corporaciones pueden invertir en *chatbots* basados en grandes modelos de lenguaje, mientras que las pymes se ven obligadas a gestionar manualmente un volumen elevado de consultas recurrentes. Esto conlleva un alto consumo de recursos humanos, tiempos de respuesta inconsistentes y una escasa escalabilidad. Como resultado, alguien siempre sale perjudicado: o el usuario final, que pierde el control y la confianza frente a su proveedor, o el pequeño empresario, incapaz de satisfacer la demanda de sus clientes.

Para paliar esta situación, existen distintas soluciones automatizadas, aunque solo resuelven el problema de forma parcial. Por un lado, los **sistemas basados en reglas y palabras clave** son más económicos y computacionalmente viables que los *chatbots*; además, otorgan mayor control al usuario, pero resultan extremadamente frágiles ante variaciones léxicas mínimas. Por otro, los ***chatbots* comerciales de propósito general** carecen de preparación para dominios específicos o para idiomas con recursos lingüísticos limitados.

Este proyecto aborda dicha problemática mediante el diseño de un **sistema de recuperación automática de respuestas** desde una base de FAQs estructurada, con soporte multilingüe nativo (español e inglés) enfocado al dominio de la cocina. Se trata estrictamente de un sistema de enrutamiento hacia información preexistente, no de un modelo generativo tipo RAG que redacte respuestas nuevas.

El dominio elegido es especialmente adecuado para una tarea de Procesamiento del Lenguaje Natural (PLN) por dos razones fundamentales: en primer lugar, la **variabilidad lingüística** de las consultas de usuario es inherentemente alta, dado que el mismo problema puede formularse de muchas formas distintas en cada idioma y con distintos registros; y en segundo lugar, la tarea de asociar una consulta a una respuesta no es resoluble mediante búsqueda exacta, sino que requiere cierta comprensión semántica y **clasificación de la intención** del mensaje.

Se implementará una PoC contextualizada en un conjunto de datos sobre cocina, ya que contiene consultas breves y variadas sobre recetas y preparación de alimentos, cercanas al tipo de preguntas recurrentes que aparecerían en un sistema FAQ real. Además, el dominio de la cocina es lo suficientemente amplio como para permitir una evaluación significativa de la capacidad del sistema para generalizar a consultas no vistas, y no tan específico como para requerir un conocimiento experto en la materia, lo que facilita el desarrollo y la evaluación del proyecto.

2. Caracterización lingüística

En esta sección se exponen las dificultades inherentes al lenguaje natural que complican el procesamiento automático en este dominio.

2.1. Ambigüedad en múltiples niveles

El lenguaje de las consultas de cocina presenta los diversos tipos de ambigüedad documentados en la teoría lingüística.

- **Nivel léxico:** Se produce cuando una misma palabra posee más de un significado. En gastronomía, la polisemia es constante. Por ejemplo, “pasta” puede referirse al alimento (“¿Cómo cocer pasta?”) o a una masa (“Me ha quedado una pasta que se pega, ¿qué hago?”). De igual forma, “yema” alude tanto a la parte del huevo (“¿Cómo puedo gastar yemas?”) como a la punta del dedo (“¿Qué utensilio uso para amasar sin mancharme las yemas?”).
- **Nivel sintáctico:** La brevedad y el uso de elipsis, habituales en los sistemas FAQ, generan múltiples interpretaciones de la estructura gramatical. En una consulta como “Pollo con verduras al horno”, la configuración sintáctica impide discernir si el complemento “al horno” afecta solo a las “verduras” (como una guarnición específica) o si, por el contrario, define el método de cocción para todo el plato.
- **Nivel semántico:** La semántica establece que el significado composicional emerge de la combinación de elementos. Sin embargo, el ámbito culinario está repleto de expresiones idiomáticas donde esta regla se rompe. El sentido de “baño María” o “punto de nieve” no se deduce sumando el significado literal de sus partes (¿Quién es “María”?). Para evitar que el sistema falle basándose solo en palabras clave, es necesario detectar marcos semánticos que capturen la acción compleja en su conjunto.
- **Nivel pragmático:** El sistema debe interpretar actos de habla indirectos. Enunciados como “Mi bizcocho parece una piedra” o “Me he quedado sin huevos” no son meras descripciones de la realidad, sino que funcionan implícitamente como peticiones de ayuda o solicitudes de alternativas.

2.2. Fenómenos específicos del género textual

Más allá de las ambigüedades puramente gramaticales, el discurso culinario presenta características semánticas y pragmáticas propias.

- **Subjetividad y carga connotativa:** La connotación evoca significados adicionales y subjetivos en las palabras. El lenguaje de cocina recurre con frecuencia a medidas imprecisas (“Recetas con un chorrito de aceite”). Traducir un “chorrito” a una cantidad objetiva es un problema complejo, ya que la connotación semántica varía según la receta

y el contexto (el volumen difiere si es vinagre, agua o aceite para una sartén frente a una ensalada).

- **Detección de metáforas y lenguaje figurado:** La jerga gastronómica emplea dominios conceptuales ajenos para describir técnicas propias (“sudar la cebolla”, “montar las claras”, “bañar el bizcocho”). Estas expresiones pueden confundir a un sistema de búsqueda exacta, requiriendo modelos capaces de capturar su semántica figurada.
- **Variación léxica y préstamos lingüísticos:** En cuanto a la dimensión sociocultural del lenguaje, la globalización ha intensificado el contacto entre lenguas, produciendo fenómenos como los préstamos léxicos. En cocina, la variabilidad es alta: un usuario puede consultar por “*cupcake*” o “magdalena”, “*airfryer*” o “freidora de aire”. Esto exige estrategias robustas de normalización de texto para estandarizar la representación antes de procesarla.
- **Impacto del contexto situacional en la actuación lingüística:** El entorno de la cocina impone una urgencia que moldea este género conversacional, priorizando la eficacia comunicativa sobre la corrección formal. Al escribir con prisas o las manos ocupadas, los usuarios generan una actuación lingüística alejada de la norma ortográfica (“q hago se me kema el arro”) por pura economía expresiva.

2.3. Complejidad multilingüe

El carácter bilingüe del asistente introduce una capa adicional de dificultad.

- **Code-switching intrafase:** Como se mencionó en el apartado de *Variación léxica y préstamos lingüísticos*, es habitual que los usuarios alternen entre español e inglés en una misma frase. Consultas como “¿A qué temperatura pongo la *airfryer* para el *bacon*?” o “Hice una tarta pero el borde no quedó *crunchy*” obligan al sistema a procesar patrones sintácticos mixtos, algo que suele confundir a los modelos entrenados en un solo idioma.
- **Variación dialectal intralingüística e inconsistencias culturales:** El español presenta una marcada variedad dialectal, por lo que el sistema debe mapear sinónimos (“patata/papa”, “zumo/jugo”, “melocotón/durazno”) a una misma representación semántica. Además, existen discrepancias culturales: el término “tortilla” requiere respuestas distintas si el usuario es de España (huevo y patata) o de México (maíz o trigo). Asimismo, el sistema debe ser capaz de procesar, normalizar y convertir consultas que combinan el sistema métrico (gramos) con el imperial (tazas, onzas), frecuente en la adaptación de recetas anglosajonas.
- **Distribución desequilibrada de recursos lingüísticos:** Existe un sesgo masivo hacia el inglés en la disponibilidad de recursos lingüísticos, tales como léxicos de cocina, bases de datos etiquetadas y modelos preentrenados.

3. Descomposición en tareas PLN

Tras el análisis lingüístico del dominio, el sistema se estructura en cuatro tareas principales, cada una con requisitos técnicos y niveles de abstracción propios.

Tarea	Descripción	Prioridad
T1: Identificación de idioma	Detección del idioma principal de entrada (español/inglés). Tarea habilitadora para el resto.	Alta
T2: Clasificación de intención	Determinación del propósito de la consulta (ej. búsqueda de receta, sustitución de ingredientes).	Muy alta
T3: Extracción de entidades	Contextualización de la intención detectada mediante la identificación de conceptos clave de cocina (ingredientes, técnicas, utensilios).	Muy alta
T4: Recuperación de FAQs	Emparejamiento semántico de la consulta procesada con la base de datos de FAQs para redirigir a la respuesta adecuada.	Alta

Estas tareas no operan de forma aislada, sino que cada etapa condiciona a la siguiente. **T1** debe ejecutarse inicialmente para determinar qué modelos o recursos léxicos activar. Superada la barrera idiomática, **T2** y **T3** actúan (en paralelo o secuencialmente) para estructurar la consulta del usuario y comprender su objetivo, transformando el lenguaje ambiguo en variables concretas (por ejemplo, extrayendo la intención “receta” y el ingrediente “huevo”). Por último, **T4** depende de la salida estructurada de T2 y T3; en lugar de buscar por palabras clave exactas, utiliza la intención y las entidades detectadas para recuperar la FAQ más relevante de la base de datos y redirigir al usuario hacia ella.

Desde la perspectiva de la **arquitectura tecnológica** del Capítulo 2, esta descomposición encaja en el modelo de niveles interdependientes. T1 opera entre el preprocesamiento fundamental (Nivel 1) y la detección de idioma (Nivel 2). T2 (clasificación textual de intenciones) y T3 (extracción de entidades nombradas) conforman el componente semántico intermedio (Nivel 2). Finalmente, T4 se sitúa en el nivel superior de aplicaciones y servicios (Nivel 3), requiriendo una arquitectura de recuperación de información basada en similitud semántica.

Nota 1. Si bien el propósito pragmático del asistente es la recuperación de la FAQ adecuada (T4), se otorga prioridad máxima a T2 y T3 por constituir el núcleo del procesamiento lingüístico. Al ser un flujo secuencial, el éxito de la respuesta final depende estrictamente de que estas tareas intermedias logren estructurar y comprender con precisión la consulta del usuario.

4. Restricciones no técnicas

El análisis del dominio y del público objetivo (pymes y sus clientes) revela un conjunto de limitaciones operacionales, legales y éticas que condicionan el diseño del sistema.

- **Viabilidad económica:** La solución se orienta a pequeñas y medianas empresas, por lo que el diseño debe ser eficiente en costes. Esta premisa restringe el empleo de modelos o infraestructuras de inferencia con requisitos computacionales excesivos que comprometan la rentabilidad del servicio.
- **Latencia:** Como interfaz interactiva de atención al cliente, el sistema exige una respuesta ágil, idealmente inferior a 200-300 ms. Un procesamiento lento degradaría la experiencia de usuario y restaría eficacia al asistente.
- **Privacidad y cumplimiento normativo:** Aunque el ámbito principal es la cocina, es frecuente que los usuarios aporten información personal o de salud (por ejemplo, “Soy diabético, ¿cómo sustituyo el azúcar?”). El sistema debe procesar intenciones y entidades garantizando la protección de esta información sensible y evitando su almacenamiento innecesario.
- **Sesgo dialectal y asimetría de recursos:** El dominio culinario presenta una gran variación léxica (patata/papa, *eggplant/aubergine*). La fuerte orientación al inglés de la mayoría de los recursos preentrenados genera un riesgo de menor precisión en español. Resulta obligatorio, por tanto, desglosar las métricas de evaluación por idioma para asegurar un rendimiento equitativo en ambos.

5. Hipótesis de diseño inicial

A partir del diagnóstico lingüístico y el marco de restricciones identificado, definimos las hipótesis de diseño que orientarán la implementación del sistema. Dada la naturaleza iterativa de este proyecto, estas propuestas son provisionales y serán revisadas en la Entrega 2.

- **T1 (identificación de idioma):** Paradigma estadístico. Para la detección del idioma de entrada (español o inglés), utilizaremos modelos basados en n -gramas de caracteres. Esta característica los hace especialmente adecuados para la tarea, ya que permite operar con latencia mínima y sobre el texto crudo. La representación estadística por n -gramas de caracteres es altamente robusta ante errores ortográficos, el *code-switching* y los préstamos léxicos identificados en la caracterización lingüística, dado que la distribución general de caracteres a nivel de oración sigue siendo discriminativa incluso con vocabulario mixto. Una vez que T1 clasifique el idioma, el mensaje será enrutado hacia un módulo de preprocesamiento y normalización específico para cada lengua (donde se abordarán cuestiones como la unificación de sinónimos tipo “papa” a “patata”), garantizando que las tareas posteriores reciban una entrada estandarizada.

- **T2 (clasificación de intención):** Paradigma estadístico-vectorial. La clasificación de intención es la tarea de mayor complejidad lingüística del sistema. Para esta primera entrega, proponemos usar un clasificador estadístico-vectorial (combinando la representación TF-IDF con un modelo SVM o regresión logística) como *baseline* sólida. Esta elección se justifica por la restricción de latencia identificada en la Sección 4, ya que estos modelos alcanzan precisiones competitivas con un coste computacional y tiempo de respuesta mínimos. Sin embargo, las dificultades identificadas en el análisis lingüístico (expresiones hechas como “sudar la cebolla” o peticiones implícitas como “me ha quedado una pasta que se pega”) sugieren que un modelo TF-IDF puede fallar ante reformulaciones semánticamente equivalentes pero léxicamente distantes. En esos casos, habría que barajar modelos de tipo Transformer multilingües preentrenados, aunque la idea inicial es mantener un paradigma sencillo.
- **T3 (extracción de entidades):** Paradigma simbólico. Esta tarea actúa como un componente de contextualización para la intención detectada en T2. Se implementará mediante un vocabulario controlado (diccionarios culinarios organizados por categorías). Al recibir la consulta ya normalizada desde T1, el sistema realizará una extracción por coincidencia de *tokens* para diferenciar casos con idéntica intención pero distintas entidades. Esta aproximación permite generar vectores de información estructurada para la resolución final en la siguiente etapa del *pipeline*.
- **T4 (recuperación de FAQs):** Paradigma vectorial. Como la consulta llega estructurada por T2 y T3, la recuperación se resuelve en dos pasos: un filtro por intención que acota el espacio de búsqueda y una búsqueda por similitud del coseno sobre las FAQs de esa categoría.

Entrega 2 — Diseño revisado

6. Revisiones respecto a la Entrega 1

Tras estudiar los modelos estadísticos, vectoriales y neuronales (Unidades 3, 4 y 5), las hipótesis iniciales del proyecto se actualizan de la siguiente manera.

- **T1 se mantiene:** La identificación automática de idiomas se resuelve de forma óptima mediante modelos estadísticos de n -gramas de caracteres. Como demuestra la ley de Zipf (Unidad 3), la alta regularidad probabilística del lenguaje convierte a estos patrones en descriptores muy discriminativos. Esta robustez asegura una detección precisa, incluso ante vocabulario especializado o errores ortográficos. Según nuestra investigación preliminar, la librería *lingua* se ajusta perfectamente a este enfoque.
- **T2 se modifica ligeramente:** El análisis de los modelos vectoriales (Unidad 4) consolida a TF-IDF como un punto de partida metodológico robusto, por lo que bastará con aplicar posteriormente un algoritmo de clasificación clásico (SVM, Naive Bayes multinomial o regresión logística). Asimismo, descartamos el uso de arquitecturas tipo Transformer debido a su excesiva complejidad para este escenario: las consultas esperadas se limitan al ámbito culinario y el conjunto de datos seleccionado (CLINC150) carece del volumen requerido para aprovechar estas redes con eficacia.
- **T3 se replantea:** Flexibilizamos el enfoque de la Entrega 1 para la extracción de entidades. La propuesta original, basada en una búsqueda léxica mediante diccionarios culinarios, puede resultar demasiado rígida porque no admite sinónimos. Para solventarlo, planteamos dos alternativas. La primera es mantener esta ruta simbólica inicial. La segunda consiste en definir palabras clave del dominio y extraer los términos de la consulta más cercanos semánticamente utilizando *embeddings* (paradigma vectorial-neuronal¹). La decisión definitiva entre ambas opciones se tomará empíricamente durante la fase de implementación.
- **T4 se simplifica para la PoC:** La falta de un corpus real de preguntas frecuentes (FAQs) impide su integración práctica en la interfaz final. Por consiguiente, el desarrollo de esta funcionalidad en la prueba de concepto se limitará a una exploración ilustrativa

¹En concreto, tenemos planteado usar la librería *spaCy*, que proporciona vectores de palabras preentrenados generados mediante el algoritmo GloVe. Estos *embeddings* son estáticos y no contextuales; es decir, cada palabra recibe una única representación vectorial fija, independientemente de la oración en la que aparezca o de sus posibles distintas acepciones. Aunque estas representaciones provienen del paradigma neuronal, nuestro sistema no realiza inferencia con redes, sino que aplica operaciones puramente algebraicas (similitud del coseno) sobre el espacio vectorial.

mediante ejemplos concretos. A nivel metodológico, proponemos evolucionar el diseño original hacia un modelo híbrido. El sistema conservaría los filtros de idioma e intención junto con la similitud del coseno (paradigma vectorial), bonificando a su vez la puntuación de aquellas FAQs que compartan *tokens* con las entidades extraídas en T3 (paradigma simbólico). Como vía alternativa de recuperación puramente léxica, también se contempla evaluar un motor de búsqueda indexada a través de Whoosh.

7. Decisiones de representación y modelado

Esta sección detalla las decisiones tomadas sobre la representación del texto y los modelos elegidos para cada componente del sistema. Las elecciones concretas se justifican en función de las restricciones identificadas en la Sección 4.

Nota 2. En vez de sintetizar la información en una tabla (indicando tarea, representación y justificación), hemos optado por un desarrollo textual pormenorizado.

7.1. Representación textual

La representación vectorial de las consultas se construirá a partir de un *pipeline* de pre-procesamiento y normalización que actúa como capa intermedia entre el texto original del usuario y el modelo de clasificación. El *pipeline* propuesto utiliza spaCy como librería principal de PLN, aplicando los siguientes pasos en orden.

1. **Expansión de contracciones y *slang*:** En el caso del inglés, se expanden las formas contraídas (*I'm* → *I am*). Para el español, se normalizan las abreviaturas coloquiales (*kiero* → *quiero*, *q* → *que*).
2. **Tokenización y conversión a minúsculas:** División del texto en *tokens* y transformación de todos los caracteres a minúsculas.
3. **Lematización con excepciones:** Se extrae el lema de cada palabra, protegiendo ciertos términos culinarios especializados (*gluten*, *aove*) de lematizaciones incorrectas mediante un diccionario de excepciones.
4. **Normalización y filtrado:** Eliminación de tildes y supresión de palabras funcionales vacías de contenido léxico (artículos, preposiciones, etc.).
5. **Sustitución de sinónimos y regionalismos:** Por ejemplo, *palta* → *aguacate*; *prawn* → *shrimp*. Se aborda así la variación dialectal señalada en la Sección 2.

Una vez normalizado el corpus, se empleará TF-IDF como representación vectorial para T2 y se entrenará un clasificador de intención independiente por idioma.

7.2. Selección de modelos

A continuación, se explican los modelos considerados para cada una de las tareas.

T1 - Identificación de idioma

Para esta tarea se utilizará **lingua**, una librería basada en modelos estadísticos que destaca por su alto rendimiento. Su procesamiento se divide en dos fases. Primero, un motor basado en reglas examina el alfabeto y los caracteres exclusivos del texto para descartar opciones incompatibles y reducir el espacio de candidatos. Después, un clasificador Naive Bayes calcula la probabilidad de cada idioma restante a partir de ***n*-gramas de caracteres** de longitud variable (de 1 a 5). A diferencia de los detectores tradicionales que se limitan a trigramas, combinar desde unigramas hasta quintigramas hace que esta herramienta sea especialmente robusta en textos cortos, como lo son las consultas de un usuario en nuestro sistema.

T2 - Clasificación de intención

Tras descartar la arquitectura Transformer (véase la Sección 6), este módulo constará de dos elementos: un vectorizador y un clasificador. El primero aplicará **TF-IDF** para transformar cada consulta en un vector de dimensión fija. En este proceso, la frecuencia del término (TF) resalta las palabras más representativas del texto, mientras que la frecuencia inversa de documento (IDF) penaliza aquellas demasiado comunes en el corpus.

Respecto al clasificador, se evaluarán distintas alternativas, siendo **SVM** el candidato principal. Este algoritmo busca el hiperplano de máximo margen que mejor separa las clases dentro del espacio vectorial generado por TF-IDF.

T3 - Extracción de entidades

La extracción de entidades se contempla desde dos enfoques distintos.

1. **Diccionarios controlados:** Se basa en la intersección entre los *tokens* normalizados de la consulta y vocabularios culinarios organizados por categoría. Es una aproximación determinista, rápida y que no requiere inferencia. Su limitación fundamental es la rigidez léxica, ya que el sistema es incapaz de extraer una entidad ausente en los diccionarios.
2. **Extracción semántica con spaCy:** Consiste en definir palabras clave del dominio culinario y extraer los términos de la consulta más cercanos semánticamente mediante el cálculo de la similitud del coseno entre los *embeddings* de dichas palabras y los *tokens* preprocesados. Al no depender de un listado cerrado, ofrece una flexibilidad mucho mayor. Esta vía requiere seleccionar un modelo apropiado entre los tres que ofrece la librería por idioma.
 - **sm** (*small*, ≈ 12 MB): Incluye tokenizador, etiquetador POS, analizador de dependencias y reconocedor de entidades nombradas (NER). Al no incorporar vectores

de palabras, es incapaz de calcular la similitud semántica.

- **md** (*medium*, ≈ 43 MB): Añade *embeddings* sobre un vocabulario de 20.000 términos (dimensión 300). Permite operaciones de similitud semántica entre *tokens*, además de incluir todas las capacidades del modelo pequeño.
- **lg** (*large*, ≈ 545 MB): Mantiene la arquitectura del modelo mediano, pero con vectores sobre un vocabulario de 685.000 términos, ofreciendo mayor cobertura semántica a costa de multiplicar por diez su tamaño.

Para la PoC, en caso de optar por esta vía, se propone el **modelo mediano** por su equilibrio entre capacidad y coste computacional.

T4 - Propuesta de enrutamiento al FAQ

Como carecemos de una base de datos real de FAQs, la recuperación no puede evaluarse de forma *end-to-end* (extremo a extremo). Por ello, se compararán dos estrategias de enrutamiento sobre un corpus artificial reducido a modo de prueba.

1. **Whoosh + BM25:** Whoosh es un motor de búsqueda indexada para Python que registra el texto en un índice invertido y recupera los documentos más relevantes usando BM25, una variante de TF-IDF optimizada para la recuperación de información. Sin embargo, esta técnica falla si el vocabulario de la consulta no coincide con el de la base de datos de FAQs; una limitación que comparte con los diccionarios controlados.
2. **Embeddings + similitud del coseno:** Se emplea el modelo mediano de spaCy para calcular y almacenar previamente los vectores de las preguntas frecuentes. En tiempo de consulta, la entrada del usuario se codifica y se calcula su similitud del coseno respecto a los vectores precalculados, filtrando antes por idioma e intención. Además, se otorgará un peso adicional a las FAQs cuyos *tokens* coincidan con las entidades detectadas en T3. Esta hibridación resulta especialmente resistente ante las reformulaciones de los usuarios. Aunque su principal desventaja reside en un mayor peso computacional, mantener los *embeddings* de las FAQs en memoria reducirá considerablemente el tiempo de respuesta en producción.

8. Datos y protocolo de evaluación

8.1. Dataset seleccionado para la PoC

Para la PoC se ha escogido el *dataset* **CLINC150** (Larson et al., 2019) en su configuración **plus**, disponible a través de la librería Datasets de Hugging Face. Este corpus es un estándar en la industria para evaluar sistemas de clasificación de intenciones en múltiples dominios.

Puesto que el proyecto se centra en un asistente de FAQs de cocina, se ha realizado un filtrado estricto para aislar este dominio, reduciendo el problema a **8 intenciones** (ejs. *recipe*,

cook_time, *ingredient_substitution*). Este filtrado define las siguientes condiciones operativas para el diseño experimental.

- **Escasez de datos:** Al acotar el dominio, el volumen del corpus disminuye significativamente. Para garantizar la reproducibilidad, se han respetado las particiones oficiales de **train/val/test**, pero fusionando **train** y **val** ante la falta de muestras. El conjunto final consta de 960 ejemplos de entrenamiento y 240 de prueba. Esta limitación justifica el uso de arquitecturas eficientes y robustas frente al sobreajuste (como TF-IDF) en lugar de modelos neuronales profundos.
- **Clases balanceadas:** Las 8 intenciones presentan un equilibrio perfecto en el número de ejemplos.
- **Soporte bilingüe:** CLINC150 es un corpus nativo en inglés. Como nuestro sistema debe soportar peticiones en español, se emplearán librerías de traducción automática para generar los datos correspondientes. Se asume el riesgo de introducir traducciones demasiado literales.
- **Ajuste de cobertura:** En la caracterización lingüística de la Entrega 1, se identificó que las consultas sobre equivalencia de medidas son frecuentes. Al no existir una intención que cubra esta casuística en CLINC150, este aspecto quedará fuera de la PoC, limitando el alcance respecto al diseño teórico inicial.

8.2. Métricas y criterio de éxito

El objetivo final de la arquitectura es actuar como un asistente de preguntas frecuentes de cocina. El sistema debe detectar la intención del usuario y redirigirlo a la respuesta adecuada. Sin embargo, no disponemos de una base de datos real de FAQs estructuradas para este dominio. Por tanto, la evaluación de la PoC no será *end-to-end*, sino que se centrará en reportar métricas sobre los módulos de **identificación de idioma** (T1) y **clasificación de intención** (T2), evaluados sobre el conjunto de test.

Dado el equilibrio perfecto de las clases, se utilizará la **tasa de aciertos** (*accuracy*) como métrica global en ambas tareas.

Adicionalmente, para T2 se calcularán la precisión, la exhaustividad (*recall*) y el **F1-score** por clase para detectar confusiones interclase (por ejemplo, si el modelo confunde “pedir una receta” con “buscar información nutricional”). Las **matrices de confusión** nos ayudarán a visualizar y analizar estas desviaciones de forma detallada. Estos resultados se desglosarán por idioma.

Como **referencia mínima**, se emplearán clasificadores uniformes (*dummy*). Al tratarse de clases balanceadas, el *baseline* se establece en un 50 % de acierto para la identificación de idioma (2 clases) y un 12.5 % para la clasificación de intención (8 clases).

Criterios de éxito de la PoC

Para considerar que la prueba de concepto es exitosa, se deben cumplir los siguientes hitos.

1. **Superar holgadamente la línea base:** Los modelos deben mejorar significativamente el rendimiento de los clasificadores triviales, esto es, el 50 % para la identificación de idioma y el 12.5 % para la clasificación de intención tanto en español como en inglés.
2. **Análisis de errores fundamentado:** Identificar los fallos de clasificación y conectarlos directamente con el análisis lingüístico de la entrega anterior.
3. **Exploración empírica para extracción (T3) y enrutamiento (T4):** Como se expuso en la charla de PLN del 14 de abril, “la intención es necesaria pero no suficiente”. Saber que el usuario busca una receta es inútil si no se extraen los alimentos o términos clave de su consulta. Por ello, el éxito práctico de la PoC consistirá en conformar adecuadamente la tupla [Idioma, Intención, Entidades] a partir de consultas de prueba representativas. Ante la falta de una base de datos de FAQs para evaluar T3 y T4 de forma integral, se explorarán empíricamente dos enfoques: una vía léxica (empleando diccionarios culinarios controlados para la extracción y motores de indexación como Whoosh para el enrutamiento) y una vía semántica (mediante la generación de *embeddings* y el cálculo de la similitud del coseno para ambos procesos).

9. Arquitectura final del sistema

El sistema se organiza en cuatro componentes principales que procesan la consulta de forma secuencial, desde la detección del idioma hasta la recuperación final de la FAQ. En esta sección, se integran los modelos seleccionados previamente para conformar el siguiente flujo de procesamiento.

- **C1 - Identificador de idioma** (lingua): Recibe el texto crudo del usuario y determina si está en español o inglés mediante modelos estadísticos de n -gramas de caracteres. Este componente actúa como un filtro inicial indispensable, ya que enruta la petición hacia el módulo de normalización y los modelos específicos de la lengua detectada.
- **C2 - Clasificador de intención** (TF-IDF + Modelos clásicos): Toma la consulta ya normalizada (lematizada, sin tildes y con sinónimos unificados) y la proyecta en un espacio vectorial para asignarle rápidamente una intención comunicativa (ejs. *meal_suggestion*, *food_last*). Se prioriza este enfoque por su alta eficiencia y bajo coste computacional en inferencia.
- **C3 - Extractor de entidades** (diccionarios o spaCy - modelo md): Trabaja con independencia de C2 para contextualizar la intención detectada y estructurar la consulta. Como se justificó en la selección de modelos, se contemplan dos alternativas.

1. **Vía léxica:** Identifica la información de interés apoyándose en diccionarios controlados por categorías culinarias. Es un método muy rápido basado en coincidencias exactas de *tokens*.
 2. **Vía semántica:** Emplea el modelo mediano de spaCy. Gracias a sus *embeddings* preentrenados, extrae las entidades relevantes calculando la distancia semántica respecto a los términos del dominio culinario, aportando así la flexibilidad de la que carece un vocabulario rígido.
- **C4 - Motor de recuperación de FAQs** (Whoosh o *embeddings* + similitud del coseno): Este último componente fusiona la intención delimitada en C2 con las entidades extraídas en C3 para buscar la respuesta óptima en la base de datos de FAQs. Se proponen dos rutas de búsqueda distintas para su evaluación.
 1. **Vía léxica** (Whoosh + BM25): Un motor veloz que indexa y recupera el texto mediante métricas estadísticas, aunque sufre dependencia léxica frente a las palabras introducidas por el usuario.
 2. **Vía semántica** (*embeddings* + similitud del coseno): Compara los *embeddings* de las entidades extraídas con los vectores precalculados de las FAQs. Esta vía complementa al motor tradicional al ser mucho más resistente frente a reformulaciones y sinónimos.




Figura 1: Diagrama del flujo de datos entre los componentes del sistema.

Como ilustra el diagrama de flujo ($\text{Consulta} \rightarrow T1 \rightarrow \{T2, T3\} \rightarrow T4 \rightarrow \text{Respuesta}$), el componente C1 precede al resto para superar la barrera idiomática. A continuación, C2 y C3 actúan de forma independiente para construir una representación estructurada de la petición. Finalmente, C4 asimila dicha salida (la tupla [Idioma, Intención, Entidades]) para devolver la FAQ adecuada al usuario.

Prueba de concepto

De cara a la PoC, la implementación abarcará el flujo completo de la arquitectura, pero el esfuerzo técnico recaerá principalmente sobre **C1**, **C2** y **C3**. El identificador de idioma (C1) y el clasificador de intención (C2) constituyen el núcleo habilitador del sistema, y pueden evaluarse de forma rigurosa utilizando el *dataset* CLINC150.

Asimismo, se pone un especial énfasis en el extractor de entidades (C3), dado que el éxito práctico de la PoC radica en conformar la tupla [Idioma, Intención, Entidades] de forma robusta. Por este motivo, aunque no sea posible evaluarlo con la misma rigurosidad métrica que los dos primeros, sí se integrará en la **interfaz final**.

Por último, y como ya se ha mencionado, la actual inexistencia de una base de datos real de FAQs de cocina impide una evaluación de extremo a extremo, lo que relega al componente C4 a una fase de exploración más reducida, limitando sus pruebas a ejemplos prácticos dentro de un cuaderno Jupyter.

Entrega 3 — Prueba de concepto y reflexión

10. Implementación

La prueba de concepto (PoC) implementa los componentes C1, C2 y C3 del pipeline al completo implementando a propósitos demostrativos C4 mediante la creación de una base de FAQs sintética. Abarcando desde la consulta del usuario hasta la generación de la tupla semántica y el enrutamiento. Todo el código, documentado y reproducible², se organiza en dos fases principales:

Preparación y preprocesamiento de datos

Como se mencionó, se ha utilizado el dataset CLINC150, realizando un filtrado estricto para aislar 8 intenciones pertenecientes al subdominio de la cocina. Debido a la reducción drástica del volumen de datos resultante, se han fusionado las particiones oficiales de entrenamiento y validación (obteniendo 960 ejemplos), reservando el conjunto de prueba (240 ejemplos) para la evaluación final. Para dar soporte al bilingüismo, el corpus original en inglés se ha replicado al español mediante traducción automática usando DEEP_TRANSLATOR. A continuación, se ha aplicado un *pipeline* de preprocesamiento robusto empleando SPACY. Este flujo incluye: expansión de contracciones, lematización con diccionarios de excepciones para proteger términos técnicos del dominio (como gluten o aove), eliminación de tildes, estandarización de variaciones dialectales (ej. mapear “papa” a “patata”), y un filtrado de *stopwords* cuidadosamente ajustado para preservar partículas de negación, fundamentales para la correcta comprensión de las consultas.

Modelado y evaluación

El núcleo de la inferencia se ha implementado de la siguiente manera:

- **C1 (identificador de idioma):** Se ha evaluado la librería LINGUA sobre una muestra aleatoria bilingüe del conjunto de prueba.
- **C2 (clasificador de intención):** Se ha realizado una búsqueda de hiperparámetros y selección de modelo mediante validación cruzada estratificada de 5 pliegues (GRIDSEARCHCV) probando **Naive Bayes**, **Regresión Logística** y **LinearSVC**. Finalmente, se ha implementado **LinearSVC** sobre representaciones de texto **TF-IDF**, entrenando un modelo totalmente independiente para el español y otro para el inglés utilizando la totalidad de los datos (siguiendo las mejores prácticas de entornos de trabajo reales).

²Disponible en el repositorio de github, <https://github.com/usuario/repositorio>

- **C3 (extracción):** se han programado las dos vías propuestas metodológicamente: extracción mediante intersección exacta con diccionarios léxicos, y extracción mediante similitud del coseno usando los *embeddings* estáticos del modelo mediano de spaCy.
- **C4 (enrutamiento):** se ha construido un entorno de demostración sobre un pequeño corpus artificial de prueba, contrastando un índice BM25 (WHOOSH) frente al cruce semántico por *embeddings*

Justificación de la implementación

La decisión de focalizar el peso del desarrollo, el entrenamiento y la evaluación cuantitativa en C1 y C2 responde a tres criterios de diseño: (1) son los componentes de enrutamiento habilitadores sin los cuales C3 y C4 carecen de información estructurada para operar; (2) permiten responder a la hipótesis de la entrega 2 comprobando empíricamente si TF-IDF + LinearSVC logran superar de forma consistente el rendimiento de un baseline trivial del 12,5 % esperado; y (3) a diferencia de la recuperación de FAQs que requiere bases de datos privativas o inexistentes, el conjunto CLINC150 dispone de etiquetas reales para acometer una evaluación rigurosa del rendimiento en la clasificación de intenciones.

Además por facilitar el uso y demostración se ha implementado también una pequeña interfaz interactiva básica en la que se demuestran los componentes C1, C2 y C3. El código e instrucciones de uso, compilación e instalación está disponible en el repositorio de github que acompaña a esta entrega.

11. Evaluación y resultados

12. Análisis de errores

13. Reflexión crítica