

Asistente de preguntas frecuentes

Proyecto longitudinal de diseño de sistemas PLN

Antonio Macías Ferrera, Elsa Domínguez González, Óscar Niño Robles

Nicolás Rodríguez Ruiz

Máster Universitario en Lógica, Computación e Inteligencia Artificial
Universidad de Sevilla

Índice

1. Justificación del dominio	2
2. Caracterización lingüística	3
2.1. Ambigüedad en múltiples niveles	3
2.2. Fenómenos específicos del género textual	3
2.3. Complejidad multilingüe	4
3. Descomposición en tareas PLN	5
4. Restricciones no técnicas	6
5. Revisiones respecto a la Entrega 1	8
6. Decisiones de representación y modelado	8
7. Datos y protocolo de evaluación	8
8. Arquitectura final del sistema	8
9. Implementación	9
10. Evaluación y resultados	9
11. Análisis de errores	9
12. Reflexión crítica	9

Entrega 1 — Análisis y diseño inicial

1. Justificación del dominio

El creciente proceso de digitalización y globalización empresarial ha transformado la gestión de la atención al cliente hacia un modelo descentralizado, externalizado y digital. Sin embargo, las tendencias actuales en este ámbito no hacen más que ampliar la brecha entre grandes organizaciones y pequeñas empresas. Las grandes corporaciones pueden invertir en *chatbots* basados en grandes modelos de lenguaje, mientras que las pymes se ven obligadas a gestionar manualmente un volumen elevado de consultas recurrentes. Esto conlleva un alto consumo de recursos humanos, tiempos de respuesta inconsistentes y una escasa escalabilidad. Como resultado, alguien siempre sale perjudicado: o el usuario final, que pierde el control y la confianza frente a su proveedor, o el pequeño empresario, incapaz de satisfacer la demanda de sus clientes.

Para paliar esta situación, existen distintas soluciones automatizadas, pero solo resuelven el problema de forma parcial. Por un lado, los **sistemas basados en reglas y palabras clave** son más económicos y computacionalmente viables que los *chatbots* y, además, otorgan más confianza y control al usuario final, pero son extremadamente frágiles ante variaciones léxicas triviales. Por otro, los ***chatbots* comerciales de propósito general** no están preparados para dominios específicos ni para idiomas con recursos lingüísticos limitados.

Este proyecto aborda dicha problemática mediante el diseño de un **sistema de recuperación automática de respuestas** desde una base de FAQs estructurada, con soporte multilingüe nativo (español e inglés) enfocado al dominio de la cocina. Se trata estrictamente de un sistema de enrutamiento hacia información preexistente, no de un modelo generativo tipo RAG que redacte respuestas nuevas.

El dominio elegido es especialmente adecuado para una tarea de Procesamiento del Lenguaje Natural (PLN) por dos razones fundamentales: en primer lugar, la **variabilidad lingüística** de las consultas de usuario es inherentemente alta, dado que el mismo problema puede formularse de muchas formas distintas en cada idioma y con distintos registros; y en segundo lugar, la tarea de asociar una consulta a una respuesta no es resoluble mediante búsqueda exacta, sino que requiere cierta comprensión semántica y **clasificación de la intención** del mensaje.

Se implementará una PoC contextualizada en un conjunto de datos sobre cocina, ya que contiene consultas breves y variadas sobre recetas y preparación de alimentos, cercanas al tipo de preguntas recurrentes que aparecerían en un sistema FAQ real. Además, el dominio de la cocina es lo suficientemente amplio como para permitir una evaluación significativa de la capacidad del sistema para generalizar a consultas no vistas, y no tan específico como para requerir un conocimiento experto en la materia, lo que facilita el desarrollo y la evaluación del proyecto.

2. Caracterización lingüística

En esta sección se exponen las dificultades inherentes al lenguaje natural que complican el procesamiento automático en este dominio.

2.1. Ambigüedad en múltiples niveles

El lenguaje de las consultas de cocina presenta los diversos tipos de ambigüedad documentados en la teoría lingüística.

- **Nivel léxico:** Se produce cuando una misma palabra posee más de un significado. En gastronomía, la polisemia es constante. Por ejemplo, “pasta” puede referirse al alimento (“¿Cómo cocer pasta?”) o a una masa (“Me ha quedado una pasta que se pega, ¿qué hago?”). De igual forma, “yema” alude tanto a la parte del huevo (“¿Cómo puedo gastar yemas?”) como a la punta del dedo (“¿Qué utensilio uso para amasar sin mancharme las yemas?”).
- **Nivel sintáctico:** La brevedad y el uso de elipsis, habituales en los sistemas FAQ, generan múltiples interpretaciones de la estructura gramatical. En una consulta como “Instrucciones para cocinar pescado sin aceite de oliva”, la falta de contexto impide discernir si se buscan recetas de pescado que por defecto no llevan aceite, o si se solicitan alternativas para sustituir este ingrediente durante la preparación.
- **Nivel semántico:** La semántica establece que el significado composicional emerge de la combinación de elementos. Sin embargo, el ámbito culinario está repleto de expresiones idiomáticas donde esta regla se rompe. El sentido de “baño María” o “punto de nieve” no se deduce sumando el significado literal de sus partes (¿Quién es “María”?). Para evitar que el sistema falle basándose solo en palabras clave, es necesario detectar marcos semánticos que capturen la acción compleja en su conjunto.
- **Nivel pragmático:** El sistema debe interpretar actos de habla indirectos. Enunciados como “Mi bizcocho parece una piedra” o “Me he quedado sin huevos” no son meras descripciones de la realidad, sino que funcionan implícitamente como peticiones de ayuda o solicitudes de alternativas.

2.2. Fenómenos específicos del género textual

Más allá de las ambigüedades puramente gramaticales, el discurso culinario presenta características semánticas y pragmáticas propias que exigen modelos de representación avanzados.

- **Subjetividad y carga connotativa:** La connotación evoca significados adicionales y subjetivos en las palabras. El lenguaje de cocina recurre con frecuencia a medidas subjetivas (“Recetas con un chorrito de aceite”). Traducir un “chorrito” a una cantidad objetiva es un problema complejo, ya que la connotación semántica varía según la receta

y el contexto (el volumen difiere si es vinagre, agua o aceite para una sartén frente a una ensalada).

- **Detección de metáforas y lenguaje figurado:** La jerga gastronómica emplea dominios conceptuales ajenos para describir técnicas propias (“sudar la cebolla”, “montar las claras”, “bañar el bizcocho”). Estas expresiones confundirían a un sistema de búsqueda exacta, requiriendo modelos capaces de capturar su semántica figurada.
- **Variación léxica y préstamos lingüísticos:** En cuanto a la dimensión sociocultural del lenguaje, la globalización ha intensificado el contacto entre lenguas, produciendo fenómenos como los préstamos léxicos. En cocina, la variabilidad es alta: un usuario puede consultar por “cupcake” o “magdalena”, “airfryer” o “freidora de aire”. Esto exige estrategias robustas de normalización de texto para estandarizar la representación antes de procesarla.
- **Impacto del contexto situacional en la actuación lingüística:** El entorno de la cocina impone una urgencia que moldea este género conversacional, priorizando la eficacia comunicativa sobre la corrección formal. Al escribir con prisas o las manos ocupadas, los usuarios generan una actuación lingüística alejada de la norma ortográfica (“q hago se me kema el arro”) por pura economía expresiva.

2.3. Complejidad multilingüe

El carácter bilingüe del asistente introduce una capa adicional de dificultad computacional.

- **Code-switching intrafase:** Como se mencionó en el apartado de *Variación léxica y préstamos lingüísticos*, es habitual que los usuarios alternen entre español e inglés en una misma frase. Consultas como “¿A qué temperatura pongo la *airfryer* para el *bacon*?” o “Hice una tarta pero el borde no quedó *crunchy*” obligan al sistema a procesar patrones sintácticos mixtos, algo que suele confundir a los modelos entrenados en un solo idioma.
- **Variación dialectal intralingüística e inconsistencias culturales:** El español presenta una marcada variedad dialectal, por lo que el sistema debe mapear sinónimos (“patata/papa”, “zumo/jugo”, “melocotón/durazno”) a una misma representación semántica. Además, existen discrepancias culturales: el término “tortilla” requiere respuestas distintas si el usuario es de España (huevo y patata) o de México (maíz o trigo). Asimismo, el sistema debe ser capaz de procesar, normalizar y convertir consultas que combinan el sistema métrico (gramos) con el imperial (tazas, onzas), frecuente en la adaptación de recetas anglosajonas.
- **Distribución desequilibrada de recursos lingüísticos:** Existe un sesgo masivo hacia el inglés en la disponibilidad de recursos lingüísticos, tales como léxicos de cocina, bases de datos etiquetadas y modelos preentrenados.

3. Descomposición en tareas PLN

Tras el análisis lingüístico del dominio, el sistema se estructura en cuatro tareas principales, cada una con requisitos técnicos y niveles de abstracción semántica propios.

Tarea	Descripción	Prioridad
T1: Identificación de idioma	Detección del idioma principal de entrada (español/inglés). Tarea habilitadora para el resto.	Alta
T2: Clasificación de intención	Determinación del propósito de la consulta (ej. búsqueda de receta, sustitución de ingredientes).	Muy alta
T3: Extracción de entidades	Contextualización de la intención detectada mediante la identificación de conceptos clave de cocina (ingredientes, técnicas, utensilios).	Muy alta
T4: Recuperación de FAQs	Emparejamiento semántico de la consulta procesada con la base de datos de FAQs para redirigir a la respuesta adecuada.	Alta

Estas tareas no operan de forma aislada, sino que cada etapa condiciona a la siguiente. **T1** debe ejecutarse inicialmente para determinar qué modelos o recursos léxicos activar. Superada la barrera idiomática, **T2** y **T3** actúan (en paralelo o secuencialmente) para estructurar la consulta del usuario y comprender su objetivo, transformando el lenguaje ambiguo en variables concretas (por ejemplo, aislando la intención “cocer” del ingrediente “huevo”). Por último, **T4** depende de la salida estructurada de T2 y T3; en lugar de buscar por palabras clave exactas, utiliza la intención y las entidades detectadas para recuperar la FAQ más relevante de la base de datos y redirigir al usuario hacia ella.

Desde la perspectiva de la **arquitectura tecnológica** del Capítulo 2, esta descomposición encaja en el modelo de niveles interdependientes. T1 opera entre el preprocesamiento fundamental (Nivel 1) y la detección de idioma (Nivel 2). T2 (clasificación textual de intenciones) y T3 (extracción de entidades nombradas) conforman el componente semántico intermedio (Nivel 2). Finalmente, T4 se sitúa en el nivel superior de aplicaciones y servicios (Nivel 3), requiriendo una arquitectura de recuperación de información basada en similitud semántica.

Nota 1. Si bien el propósito pragmático del asistente es la recuperación de la FAQ adecuada (T4), se otorga prioridad máxima a T2 y T3 por constituir el núcleo del procesamiento lingüístico. Al ser un flujo secuencial, el éxito de la respuesta final depende estrictamente de que estas tareas intermedias logren estructurar y comprender con precisión la consulta del usuario.

4. Restricciones no técnicas

El análisis del dominio y del público objetivo (pymes y sus clientes) revela un conjunto de limitaciones operacionales, legales y éticas que condicionarán el diseño del sistema.

- **Viabilidad económica:** La solución se orienta a pequeñas y medianas empresas, por lo que el diseño debe ser eficiente en costes. Esta premisa restringe el empleo de modelos o infraestructuras de inferencia con requisitos computacionales excesivos que comprometan la rentabilidad del servicio.
- **Latencia:** Como interfaz interactiva de atención al cliente, el sistema exige una respuesta ágil, idealmente inferior a 200-300 ms. Un procesamiento lento degradaría la experiencia de usuario y restaría eficacia al asistente.
- **Privacidad y cumplimiento normativo:** Aunque el ámbito principal es la cocina, es frecuente que los usuarios aporten información personal o de salud (por ejemplo, “Soy diabético, ¿cómo sustituyo el azúcar?”). El sistema debe procesar intenciones y entidades garantizando la protección de esta información sensible y evitando su almacenamiento innecesario.
- **Sesgo dialectal y asimetría de recursos:** El dominio culinario presenta una gran variación léxica (patata/papa, *eggplant/aubergine*). La fuerte orientación al inglés de la mayoría de los recursos preentrenados genera un riesgo de menor precisión en español. Resulta obligatorio, por tanto, desglosar las métricas de evaluación por idioma para asegurar un rendimiento equitativo en ambos.

T1: Identificación de idioma

Paradigma estadístico. Para la detección del idioma de entrada (español o inglés), usaremos modelos basados en n-gramas de caracteres. Esta característica los hace especialmente adecuados para la tarea que debe resolverse antes que cualquier otra en el *pipeline*. Antes de la detección propiamente dicha, T1 incorpora una etapa de **normalización de texto** que unifica sinónimos (“papa” → “patata”), préstamos léxicos (“airfryer” → “freidora de aire”) y errores ortográficos frecuentes. Esta normalización es transversal al pipeline: la consulta que sale de T1 ya está estandarizada y es la que reciben T2 y T3. La representación por n-gramas de caracteres es, además, robusta ante el *code-switching* y los préstamos léxicos identificados en la Sección 2, ya que la distribución de patrones de caracteres a nivel de oración sigue siendo discriminativa incluso con vocabulario mixto.

T2: Clasificación de intención

Paradigma estadístico. La clasificación de intención es la tarea de mayor complejidad lingüística del sistema. Para esta primera entrega, proponemos usar un clasificador estadístico (TF-IDF con LinearSVC o Regresión Logística) como *baseline* sólida para un corpus de

entrenamiento relativamente acotado. La literatura muestra que este tipo de clasificadores puede alcanzar precisiones superiores al 90 % en tareas de clasificación de texto cuando el vocabulario del dominio es consistente.

Sin embargo, las dificultades identificadas en la Sección 2 (expresiones hechas como “*sudar la cebolla*” o peticiones implícitas como “*me ha quedado una pasta que se pega*”) sugieren que un modelo TF-IDF puede fallar ante reformulaciones semánticamente equivalentes pero léxicamente distantes. En esos casos habría que barajar modelos Transformer multilingües pre-entrenados, aunque la idea principal es mantener el paradigma estadístico, dada la restricción de latencia de la Sección 4.

T3: Extracción de entidades

Paradigma basado en vocabulario controlado. T3 contextualiza la intención de T2: dos consultas con la misma intención pero entidades distintas (“*huevo*” frente a “*mantequilla*”) deben llegar a T4 con vectores diferenciados. Dado que la consulta ya llega normalizada desde T1, T3 se reduce a calcular la intersección entre sus tokens y un diccionario de entidades culinarias organizado por categorías.

T4: Recuperación de FAQs

Paradigma vectorial filtrado por intención. Dado que T2 y T3 estructuran la consulta antes de que llegue a T4, el problema de recuperación puede resolverse en dos pasos: primero, un **filtro por intención** que reduce el espacio de búsqueda al subconjunto de FAQs de la categoría correspondiente, seguido de una **búsqueda por similitud coseno** sobre los embeddings de ese subconjunto. Para la representación vectorial, y dado el tamaño previsible de la base FAQ, esto puede implementarse directamente usando `cosine_similarity`.



Entrega 2 — Diseño revisado

Comentar secciones antes de entregar. Están de referencia.

5. Revisiones respecto a la Entrega 1
6. Decisiones de representación y modelado
7. Datos y protocolo de evaluación
8. Arquitectura final del sistema

Entrega 3 — Prueba de concepto y reflexión

Comentar secciones antes de entregar. Están de referencia.

9. Implementación

10. Evaluación y resultados

11. Análisis de errores

12. Reflexión crítica