

Asistente de preguntas frecuentes

Proyecto longitudinal de diseño de sistemas PLN

Antonio Macías Ferrera, Elsa Domínguez González, Óscar Niño Robles
Nicolás Rodríguez Ruiz

Máster Universitario en Lógica, Computación e Inteligencia Artificial
Universidad de Sevilla

Índice

1. Justificación del dominio	2
2. Caracterización lingüística	3
2.1. Ambigüedad en múltiples niveles	3
2.2. Fenómenos específicos del género textual	3
2.3. Complejidad multilingüe	4
3. Descomposición en tareas PLN	5
4. Restricciones no técnicas	6
5. Hipótesis de diseño inicial	6
6. Revisiones respecto a la Entrega 1	8
7. Decisiones de representación y modelado	9
7.1. Representación textual	9
7.2. Selección de modelos	10
8. Datos y protocolo de evaluación	13
8.1. Dataset seleccionado para la PoC	13
8.2. Métricas y criterio de éxito	13
9. Arquitectura final del sistema	15

Entrega 1 — Análisis y diseño inicial

1. Justificación del dominio

El creciente proceso de digitalización y globalización empresarial ha transformado la gestión de la atención al cliente hacia un modelo descentralizado, externalizado y digital. Sin embargo, las tendencias actuales en este ámbito no hacen más que ampliar la brecha entre grandes organizaciones y pequeñas empresas. Las grandes corporaciones pueden invertir en *chatbots* basados en grandes modelos de lenguaje, mientras que las pymes se ven obligadas a gestionar manualmente un volumen elevado de consultas recurrentes. Esto conlleva un alto consumo de recursos humanos, tiempos de respuesta inconsistentes y una escasa escalabilidad. Como resultado, alguien siempre sale perjudicado: o el usuario final, que pierde el control y la confianza frente a su proveedor, o el pequeño empresario, incapaz de satisfacer la demanda de sus clientes.

Para paliar esta situación, existen distintas soluciones automatizadas, aunque solo resuelven el problema de forma parcial. Por un lado, los **sistemas basados en reglas y palabras clave** son más económicos y computacionalmente viables que los *chatbots*; además, otorgan mayor control al usuario, pero resultan extremadamente frágiles ante variaciones léxicas mínimas. Por otro, los ***chatbots* comerciales de propósito general** carecen de preparación para dominios específicos o para idiomas con recursos lingüísticos limitados.

Este proyecto aborda dicha problemática mediante el diseño de un **sistema de recuperación automática de respuestas** desde una base de FAQs estructurada, con soporte multilingüe nativo (español e inglés) enfocado al dominio de la cocina. Se trata estrictamente de un sistema de enrutamiento hacia información preexistente, no de un modelo generativo tipo RAG que redacte respuestas nuevas.

El dominio elegido es especialmente adecuado para una tarea de Procesamiento del Lenguaje Natural (PLN) por dos razones fundamentales: en primer lugar, la **variabilidad lingüística** de las consultas de usuario es inherentemente alta, dado que el mismo problema puede formularse de muchas formas distintas en cada idioma y con distintos registros; y en segundo lugar, la tarea de asociar una consulta a una respuesta no es resoluble mediante búsqueda exacta, sino que requiere cierta comprensión semántica y **clasificación de la intención** del mensaje.

Se implementará una PoC contextualizada en un conjunto de datos sobre cocina, ya que contiene consultas breves y variadas sobre recetas y preparación de alimentos, cercanas al tipo de preguntas recurrentes que aparecerían en un sistema FAQ real. Además, el dominio de la cocina es lo suficientemente amplio como para permitir una evaluación significativa de la capacidad del sistema para generalizar a consultas no vistas, y no tan específico como para requerir un conocimiento experto en la materia, lo que facilita el desarrollo y la evaluación del proyecto.

2. Caracterización lingüística

En esta sección se exponen las dificultades inherentes al lenguaje natural que complican el procesamiento automático en este dominio.

2.1. Ambigüedad en múltiples niveles

El lenguaje de las consultas de cocina presenta los diversos tipos de ambigüedad documentados en la teoría lingüística.

- **Nivel léxico:** Se produce cuando una misma palabra posee más de un significado. En gastronomía, la polisemia es constante. Por ejemplo, “pasta” puede referirse al alimento (“¿Cómo cocer pasta?”) o a una masa (“Me ha quedado una pasta que se pega, ¿qué hago?”). De igual forma, “yema” alude tanto a la parte del huevo (“¿Cómo puedo gastar yemas?”) como a la punta del dedo (“¿Qué utensilio uso para amasar sin mancharme las yemas?”).
- **Nivel sintáctico:** La brevedad y el uso de elipsis, habituales en los sistemas FAQ, generan múltiples interpretaciones de la estructura gramatical. En una consulta como “Pollo con verduras al horno”, la configuración sintáctica impide discernir si el complemento “al horno” afecta solo a las “verduras” (como una guarnición específica) o si, por el contrario, define el método de cocción para todo el plato.
- **Nivel semántico:** La semántica establece que el significado composicional emerge de la combinación de elementos. Sin embargo, el ámbito culinario está repleto de expresiones idiomáticas donde esta regla se rompe. El sentido de “baño María” o “punto de nieve” no se deduce sumando el significado literal de sus partes (¿Quién es “María”?). Para evitar que el sistema falle basándose solo en palabras clave, es necesario detectar marcos semánticos que capturen la acción compleja en su conjunto.
- **Nivel pragmático:** El sistema debe interpretar actos de habla indirectos. Enunciados como “Mi bizcocho parece una piedra” o “Me he quedado sin huevos” no son meras descripciones de la realidad, sino que funcionan implícitamente como peticiones de ayuda o solicitudes de alternativas.

2.2. Fenómenos específicos del género textual

Más allá de las ambigüedades puramente gramaticales, el discurso culinario presenta características semánticas y pragmáticas propias.

- **Subjetividad y carga connotativa:** La connotación evoca significados adicionales y subjetivos en las palabras. El lenguaje de cocina recurre con frecuencia a medidas imprecisas (“Recetas con un chorrito de aceite”). Traducir un “chorrito” a una cantidad objetiva es un problema complejo, ya que la connotación semántica varía según la receta

y el contexto (el volumen difiere si es vinagre, agua o aceite para una sartén frente a una ensalada).

- **Detección de metáforas y lenguaje figurado:** La jerga gastronómica emplea dominios conceptuales ajenos para describir técnicas propias (“sudar la cebolla”, “montar las claras”, “bañar el bizcocho”). Estas expresiones pueden confundir a un sistema de búsqueda exacta, requiriendo modelos capaces de capturar su semántica figurada.
- **Variación léxica y préstamos lingüísticos:** En cuanto a la dimensión sociocultural del lenguaje, la globalización ha intensificado el contacto entre lenguas, produciendo fenómenos como los préstamos léxicos. En cocina, la variabilidad es alta: un usuario puede consultar por “*cupcake*” o “magdalena”, “*airfryer*” o “freidora de aire”. Esto exige estrategias robustas de normalización de texto para estandarizar la representación antes de procesarla.
- **Impacto del contexto situacional en la actuación lingüística:** El entorno de la cocina impone una urgencia que moldea este género conversacional, priorizando la eficacia comunicativa sobre la corrección formal. Al escribir con prisas o las manos ocupadas, los usuarios generan una actuación lingüística alejada de la norma ortográfica (“q hago se me kema el arro”) por pura economía expresiva.

2.3. Complejidad multilingüe

El carácter bilingüe del asistente introduce una capa adicional de dificultad.

- **Code-switching intrafase:** Como se mencionó en el apartado de *Variación léxica y préstamos lingüísticos*, es habitual que los usuarios alternen entre español e inglés en una misma frase. Consultas como “¿A qué temperatura pongo la *airfryer* para el *bacon*?” o “Hice una tarta pero el borde no quedó *crunchy*” obligan al sistema a procesar patrones sintácticos mixtos, algo que suele confundir a los modelos entrenados en un solo idioma.
- **Variación dialectal intralingüística e inconsistencias culturales:** El español presenta una marcada variedad dialectal, por lo que el sistema debe mapear sinónimos (“patata/papa”, “zumو/jugo”, “melocotón/durazno”) a una misma representación semántica. Además, existen discrepancias culturales: el término “tortilla” requiere respuestas distintas si el usuario es de España (huevo y patata) o de México (maíz o trigo). Asimismo, el sistema debe ser capaz de procesar, normalizar y convertir consultas que combinan el sistema métrico (gramos) con el imperial (tazas, onzas), frecuente en la adaptación de recetas anglosajonas.
- **Distribución desequilibrada de recursos lingüísticos:** Existe un sesgo masivo hacia el inglés en la disponibilidad de recursos lingüísticos, tales como léxicos de cocina, bases de datos etiquetadas y modelos preentrenados.

3. Descomposición en tareas PLN

Tras el análisis lingüístico del dominio, el sistema se estructura en cuatro tareas principales, cada una con requisitos técnicos y niveles de abstracción propios.

Tarea	Descripción	Prioridad
T1: Identificación de idioma	Detección del idioma principal de entrada (español/inglés). Tarea habilitadora para el resto.	Alta
T2: Clasificación de intención	Determinación del propósito de la consulta (ej. búsqueda de receta, sustitución de ingredientes).	Muy alta
T3: Extracción de entidades	Contextualización de la intención detectada mediante la identificación de conceptos clave de cocina (ingredientes, técnicas, utensilios).	Muy alta
T4: Recuperación de FAQs	Emparejamiento semántico de la consulta procesada con la base de datos de FAQs para redirigir a la respuesta adecuada.	Alta

Estas tareas no operan de forma aislada, sino que cada etapa condiciona a la siguiente. **T1** debe ejecutarse inicialmente para determinar qué modelos o recursos léxicos activar. Superada la barrera idiomática, **T2** y **T3** actúan (en paralelo o secuencialmente) para estructurar la consulta del usuario y comprender su objetivo, transformando el lenguaje ambiguo en variables concretas (por ejemplo, extrayendo la intención “receta” y el ingrediente “huevo”). Por último, **T4** depende de la salida estructurada de T2 y T3; en lugar de buscar por palabras clave exactas, utiliza la intención y las entidades detectadas para recuperar la FAQ más relevante de la base de datos y redirigir al usuario hacia ella.

Desde la perspectiva de la **arquitectura tecnológica** del Capítulo 2, esta descomposición encaja en el modelo de niveles interdependientes. T1 opera entre el preprocesamiento fundamental (Nivel 1) y la detección de idioma (Nivel 2). T2 (clasificación textual de intenciones) y T3 (extracción de entidades nombradas) conforman el componente semántico intermedio (Nivel 2). Finalmente, T4 se sitúa en el nivel superior de aplicaciones y servicios (Nivel 3), requiriendo una arquitectura de recuperación de información basada en similitud semántica.

Nota 1. Si bien el propósito pragmático del asistente es la recuperación de la FAQ adecuada (T4), se otorga prioridad máxima a T2 y T3 por constituir el núcleo del procesamiento lingüístico. Al ser un flujo secuencial, el éxito de la respuesta final depende estrictamente de que estas tareas intermedias logren estructurar y comprender con precisión la consulta del usuario.

4. Restricciones no técnicas

El análisis del dominio y del público objetivo (pymes y sus clientes) revela un conjunto de limitaciones operacionales, legales y éticas que condicionan el diseño del sistema.

- **Viabilidad económica:** La solución se orienta a pequeñas y medianas empresas, por lo que el diseño debe ser eficiente en costes. Esta premisa restringe el empleo de modelos o infraestructuras de inferencia con requisitos computacionales excesivos que comprometan la rentabilidad del servicio.
- **Latencia:** Como interfaz interactiva de atención al cliente, el sistema exige una respuesta ágil, idealmente inferior a 200-300 ms. Un procesamiento lento degradaría la experiencia de usuario y restaría eficacia al asistente.
- **Privacidad y cumplimiento normativo:** Aunque el ámbito principal es la cocina, es frecuente que los usuarios aporten información personal o de salud (por ejemplo, “Soy diabético, ¿cómo sustituyo el azúcar?”). El sistema debe procesar intenciones y entidades garantizando la protección de esta información sensible y evitando su almacenamiento innecesario.
- **Sesgo dialectal y asimetría de recursos:** El dominio culinario presenta una gran variación léxica (patata/papa, *eggplant/aubergine*). La fuerte orientación al inglés de la mayoría de los recursos preentrenados genera un riesgo de menor precisión en español. Resulta obligatorio, por tanto, desglosar las métricas de evaluación por idioma para asegurar un rendimiento equitativo en ambos.

5. Hipótesis de diseño inicial

A partir del diagnóstico lingüístico y el marco de restricciones identificado, definimos las hipótesis de diseño que orientarán la implementación del sistema. Dada la naturaleza iterativa de este proyecto, estas propuestas son provisionales y serán revisadas en la Entrega 2.

- **T1 (identificación de idioma):** Paradigma estadístico. Para la detección del idioma de entrada (español o inglés), utilizaremos modelos basados en n -gramas de caracteres. Esta característica los hace especialmente adecuados para la tarea, ya que permite operar con latencia mínima y sobre el texto crudo. La representación estadística por n -gramas de caracteres es altamente robusta ante errores ortográficos, el *code-switching* y los préstamos léxicos identificados en la caracterización lingüística, dado que la distribución general de caracteres a nivel de oración sigue siendo discriminativa incluso con vocabulario mixto. Una vez que T1 clasifique el idioma, el mensaje será enrutado hacia un módulo de preprocesamiento y normalización específico para cada lengua (donde se abordarán cuestiones como la unificación de sinónimos tipo “papa” a “patata”), garantizando que las tareas posteriores reciban una entrada estandarizada.

- **T2 (clasificación de intención):** Paradigma estadístico-vectorial. La clasificación de intención es la tarea de mayor complejidad lingüística del sistema. Para esta primera entrega, proponemos usar un clasificador estadístico-vectorial (combinando la representación TF-IDF con un modelo SVM o regresión logística) como *baseline* sólida. Esta elección se justifica por la restricción de latencia identificada en la Sección 4, ya que estos modelos alcanzan precisiones competitivas con un coste computacional y tiempo de respuesta mínimos. Sin embargo, las dificultades identificadas en el análisis lingüístico (expresiones hechas como “sudar la cebolla” o peticiones implícitas como “me ha quedado una pasta que se pega”) sugieren que un modelo TF-IDF puede fallar ante reformulaciones semánticamente equivalentes pero léxicamente distantes. En esos casos, habría que barajar modelos de tipo Transformer multilingües preentrenados, aunque la idea inicial es mantener un paradigma sencillo.
- **T3 (extracción de entidades):** Paradigma simbólico. Esta tarea actúa como un componente de contextualización para la intención detectada en T2. Se implementará mediante un vocabulario controlado (diccionarios culinarios organizados por categorías). Al recibir la consulta ya normalizada desde T1, el sistema realizará una extracción por coincidencia de *tokens* para diferenciar casos con idéntica intención pero distintas entidades. Esta aproximación permite generar vectores de información estructurada para la resolución final en la siguiente etapa del *pipeline*.
- **T4 (recuperación de FAQs):** Paradigma vectorial. Como la consulta llega estructurada por T2 y T3, la recuperación se resuelve en dos pasos: un filtro por intención que acota el espacio de búsqueda y una búsqueda por similitud coseno sobre las FAQs de esa categoría.

Entrega 2 — Diseño revisado

6. Revisiones respecto a la Entrega 1

ÓSCAR

7. Decisiones de representación y modelado

Esta sección detalla las decisiones tomadas sobre la representación del texto y los modelos elegidos para cada componente del *pipeline*. Las elecciones concretas se justifican en función de las restricciones identificadas en la Sección 4 y de los resultados obtenidos durante la experimentación.

7.1. Representación textual

La representación vectorial de las consultas se construye a partir de un *pipeline* de pre-procesamiento y normalización que actúa como capa intermedia entre el texto original del usuario y el modelo de clasificación. El *pipeline* aplica los siguientes pasos en orden:

1. **Expansión de contracciones y *slang*:** en el caso del inglés se expanden formas contraídas (*I'm* → *I am*) con la librería **contractions**. Para el español, se normalizan abreviaturas coloquiales mediante reglas (*kiero* → *quiero*, *q* → *que*).
2. **Lematización con excepciones:** Se aplica el lematizador de spaCy, protegiendo del lema incorrecto a términos técnico-culinarios (*gluten*, *pizza*, *aove*) mediante un diccionario de excepciones.
3. **Normalización:** Eliminación de tildes y conversión a minúsculas mediante **unidecode**, eliminación de palabras funcionales vacías de contenido léxico.
4. **Sustitución de sinónimos y regionalismos:** sustituyendo *papa* → *patata*; *palta* → *aguacate*; *prawn* → *shrimp*, abordando de esta forma la variación dialectal señalada en la Sección 2.

Esta normalización inicial de los textos de entrada se traduce en una reducción significativa del vocabulario: de 855 a 628 tipos únicos en inglés y de 1 212 a 679 en español, con una reducción media de la longitud de consulta de aproximadamente el 35 % en ambos idiomas. Este compactado del vocabulario favorece la generalización del modelo de clasificación.

Sobre el corpus normalizado, la representación vectorial empleada para T2 es **TF-IDF** (*Term Frequency-Inverse Document Frequency*). Esta elección de este modelo en específico se ha considerado la más adecuada para la tarea de clasificación de la intención por dos razones: primero, porque permite capturar los términos discriminativos por intención (por ejemplo, *sustituir* para *ingredient_substitution* o *caduca/last* para *food_last*); y luego, porque a nivel de implementación se puede integrar directamente en el *pipeline* con el clasificador **LinearSVC**. Se entrena un modelo independiente por idioma, en coherencia con la arquitectura de T1: tras detectar el idioma, la consulta se enruta al vectorizador y clasificador correspondiente.

7.2. Selección de modelos

T1 - Identificación de idioma

Para la detección de idioma se utiliza **lingua**, librería basada en modelos estadísticos de n -gramas¹. La evaluación sobre los 480 ejemplos del conjunto de prueba bilingüe ofrece una tasa de aciertos del **100 %**.

Lingua usa un procesamiento comprendido en dos fases: primero, un **motor basado en reglas** examina el alfabeto y los caracteres exclusivos del texto para descartar idiomas incompatibles y podar el espacio de candidatos; después, un **clasificador Naive Bayes** calcula la probabilidad de cada idioma restante a partir de n -gramas de caracteres de longitud variable (de 1 a 5). A diferencia de los detectores tradicionales que se limitan a trigramas, el uso de unigramas hasta quintigramas hace a Lingua especialmente robusto en textos cortos.

T2 - Clasificación de intención

La clasificación de intención se implementa mediante una cadena de dos componentes: un vectorizador **TF-IDF** y un clasificador **LinearSVC**. Se entrena un modelo independiente por idioma: una vez que T1 determina la lengua de la consulta, ésta se enruta al par vectorizador-clasificador correspondiente.

TF-IDF (*Term Frequency-Inverse Document Frequency*) transforma cada consulta de texto en un vector. La componente TF (*term frequency*) pondera cada término en proporción a su frecuencia dentro del documento, y la componente IDF (*inverse document frequency*) penaliza los términos que aparecen en muchos documentos del corpus reduciendo el peso de palabras comunes.

LinearSVC (*Support Vector Classifier* lineal) busca el hiperplano que separa las clases en el espacio vectorial generado por TF-IDF. El parámetro de regularización se fija en $C = 1$, valor que equilibra margen y tolerancia a errores de entrenamiento dado el reducido tamaño del corpus.

Los primeros resultados sobre el conjunto de prueba muestran una *accuracy* del **93 %** en inglés y **94 %** en español, con F1 macro de 0,93 y 0,94 respectivamente, superando ampliamente el 12,5 % del clasificador trivial. Los errores residuales se concentran en los pares *recipe/ingredients_list* y *calories/nutrition_info*, cuyo solapamiento léxico dificulta la separación mediante representación de bolsa de palabras.

T3 - Extracción de entidades

La tarea de extracción de entidades se ha contemplado desde dos enfoques distintos:

¹Toda la arquitectura técnica de Lingua, incluyendo la sección «*How does it work under the hood?*», está documentada en los repositorios oficiales: <https://github.com/pemistahl/lingua> (implementación original en Java) y <https://github.com/pemistahl/lingua-py> (implementación en Python).

Vía 1 - Diccionarios controlados. Se realiza una extracción por intersección de los *tokens* normalizados de la consulta con vocabularios culinarios organizados por categoría: ingredientes, técnicas culinarias y utensilios (entre 18 y 47 entradas por idioma y categoría). Esta aproximación es determinista, rápida y no requiere inferencia. La limitación fundamental es la **rigidez léxica** debido a que el sistema no puede extraer ninguna entidad que no figure en el diccionario. Esto exige un mantenimiento continuo del vocabulario controlado.

Vía 2 - Extracción simbólico-semántica con spaCy (implementada). Una alternativa más flexible consiste en hacer uso de la librería spaCy para extraer todos los sustantivos (NOUN) y nombres propios (PROPN) de la consulta, sin necesidad de vocabulario predefinido. Esta vía requiere seleccionar el modelo de spaCy apropiado. La biblioteca ofrece tres tamaños para cada idioma:

- **sm** (*small*, ≈ 12 MB): incluye tokenizador, etiquetador POS, analizador de dependencias y reconocedor de entidades nombradas (NER), pero **no incorpora vectores de palabras**. Apto para la extracción de sustantivos por POS, pero incapaz de calcular similitud semántica entre *tokens*.
- **md** (*medium*, ≈ 43 MB): añade vectores de palabras sobre un vocabulario de 20 000 términos (dimensión 300). Permite operaciones de similitud semántica entre *tokens* mediante `token.similarity()`, además de todas las capacidades del modelo pequeño.
- **lg** (*large*, ≈ 545 MB): misma arquitectura que el modelo mediano pero con vectores sobre un vocabulario de 685 000 términos, ofreciendo mayor cobertura semántica a costa de un tamaño diez veces superior.

Para la PoC se ha optado por el **modelo mediano** como equilibrio entre capacidad y coste. La combinación de extracción de sustantivos por POS con los vectores estáticos del modelo mediano posibilitaría, además, calcular la distancia semántica entre los sustantivos extraídos y los términos canónicos del dominio, ampliando la cobertura de T3 más allá de las limitaciones del vocabulario controlado.

T4 - Propuesta de enrutamiento FAQ

Al no disponer de una base de datos real de FAQs, la recuperación no puede evaluarse de forma *end-to-end*. Se proponen y comparan dos estrategias de enrutamiento sobre un corpus de FAQs artificial de demostración, bilingüe (12 entradas, 8 en español y 4 en inglés).

Whoosh + BM25. Whoosh es un motor de búsqueda de texto completo implementado en Python puro. Indexa el texto de las preguntas de la base de FAQs en un **índice invertido** y recupera los documentos más relevantes usando el algoritmo **BM25**, una variante de TF-IDF optimizada para recuperación de información. Aunque esta solución conseguiría un rendimiento muy óptimo, no termina siendo totalmente adecuada ya que esta indexación no permite contemplar el caso en el que el vocabulario de la consulta no coincida con el de la

FAQ. Esta dependencia léxica es una limitación estructural de Whoosh que comparte con los diccionarios controlados.

***Embeddings* + similitud coseno.** Se emplea el modelo *paraphrase-multilingual-MiniLM-L12-v2*, preentrenado en tareas de similitud de en múltiples idiomas. Los vectores de las FAQs se calculan y se almacenan; en tiempo de consulta, se codifica únicamente la consulta y se calcula la similitud coseno contra los vectores precalculados, filtrando previamente por intención. Esta opción sí puede llegar a ser resistente ante reformulaciones. La principal desventaja es su mayor peso computacional. No obstante, al precalcular los *embeddings* de las FAQs y mantenerlos en memoria, la inferencia en producción se reduce a una codificación de la consulta y una multiplicación matricial, operación de coste controlable.

8. Datos y protocolo de evaluación

8.1. Dataset seleccionado para la PoC

Para la PoC se utilizará el dataset **CLINC150** (Larson et al., 2019) en su configuración **plus**, disponible a través de la librería Datasets de Hugging Face. Este corpus es un estándar en la industria para evaluar sistemas de clasificación de intenciones en múltiples dominios.

Puesto que el proyecto se centra en un asistente de FAQs de cocina, se ha realizado un filtrado estricto para aislar este dominio, reduciendo el problema a **8 intenciones** (ejs. *recipe*, *cook_time*, *ingredient_substitution*). Este filtrado define las siguientes condiciones operativas para el diseño experimental.

- **Escasez de datos:** Al acotar el dominio, el volumen del corpus disminuye significativamente. Para garantizar la reproducibilidad, se han respetado las particiones oficiales de **train/val/test**, pero fusionando **train** y **val** ante la falta de muestras. El conjunto final consta de 960 ejemplos de entrenamiento y 240 de prueba. Esta limitación justifica el uso de arquitecturas eficientes y robustas frente al sobreajuste (como TF-IDF) en lugar de modelos neuronales profundos.
- **Clases balanceadas:** Las 8 intenciones presentan un equilibrio perfecto en el número de ejemplos.
- **Soporte bilingüe:** CLINC150 es un corpus nativo en inglés. Como nuestro sistema debe soportar peticiones en español, se emplearán librerías de traducción automática para generar los datos correspondientes. Se asume el riesgo de introducir traducciones demasiado literales.
- **Ajuste de cobertura:** En la caracterización lingüística de la Entrega 1, se identificó que las consultas sobre equivalencia de medidas son frecuentes. Al no existir una intención que cubra esta casuística en CLINC150, este aspecto quedará fuera de la PoC, limitando el alcance respecto al diseño teórico inicial.

8.2. Métricas y criterio de éxito

El objetivo final de la arquitectura es actuar como un asistente de preguntas frecuentes de cocina. El sistema debe detectar la intención del usuario y redirigirlo a la respuesta adecuada. Sin embargo, no disponemos de una base de datos real de FAQs estructuradas para este dominio. Por tanto, la evaluación de la PoC no será *end-to-end* (extremo a extremo), sino que se centrará en reportar métricas sobre los módulos de **identificación de idioma** (T1) y **clasificación de intención** (T2), evaluados sobre el conjunto de test.

Dado el equilibrio perfecto de las clases, se utilizará la **tasa de aciertos** (*accuracy*) como métrica global en ambas tareas.

Adicionalmente, para T2 se calcularán la precisión, la exhaustividad (*recall*) y el **F1-score** por clase para detectar confusiones interclase (por ejemplo, si el modelo confunde “pedir una receta” con “buscar información nutricional”). Las **matrices de confusión** nos ayudarán a visualizar y analizar estas desviaciones de forma detallada. Estos resultados se desglosarán por idioma.

Como **referencia mínima**, se emplearán clasificadores uniformes (*dummy*). Al tratarse de clases balanceadas, el *baseline* se establece en un 50 % de acierto para la identificación de idioma (2 clases) y un 12.5 % para la clasificación de intención (8 clases).

Criterios de éxito de la PoC

Para considerar que la prueba de concepto es exitosa, se deben cumplir los siguientes hitos.

1. **Superar holgadamente la línea base:** Los modelos deben mejorar significativamente el rendimiento de los clasificadores triviales, esto es, el 50 % para la identificación de idioma y el 12.5 % para la clasificación de intención en ambos idiomas.
2. **Análisis de errores fundamentado:** Identificar los fallos de clasificación y conectarlos directamente con el análisis lingüístico de la entrega anterior.
3. **Exploración empírica para extracción (T3) y enrutamiento (T4):** Como se expuso en la charla de PLN del 14 de abril, “la intención es necesaria pero no suficiente”. Saber que el usuario busca una receta es inútil si no se extraen los alimentos o términos clave de su consulta. Por ello, el éxito práctico de la PoC consistirá en conformar adecuadamente la tupla [Idioma, Intención, Entidades] a partir de consultas de prueba representativas. Ante la falta de una base de datos de FAQs para evaluar T3 y T4 de forma integral, se explorarán empíricamente dos enfoques: una vía léxica (empleando diccionarios culinarios controlados para la extracción y motores de indexación como Whoosh para el enrutamiento) y una vía semántica (mediante la generación de *embeddings* y el cálculo de similitud coseno para ambos procesos).

9. Arquitectura final del sistema

El sistema se organiza en cuatro componentes principales que procesan la consulta del usuario de forma secuencial, cubriendo desde la detección del idioma hasta la recuperación final de la FAQ. El flujo de procesamiento es el siguiente:

- **C1 - Identificador de idioma** (Lingua): Recibe el texto crudo introducido por el usuario y determina si está en español o inglés mediante modelos estadísticos de n-gramas de caracteres. Esta tarea (T1) es el filtro inicial indispensable que enruta la consulta hacia el módulo de normalización y los modelos específicos de la lengua detectada.
- **C2 - Clasificador de intención** (TF-IDF + Modelos Clásicos): Recibe la consulta ya normalizada (sin tildes, lematizada y con sinónimos resueltos) y la transforma en un espacio vectorial para clasificar su intención comunicativa (ej. *recipe*, *ingredient_substitution*) con un coste computacional y tiempo de respuesta mínimos.
- **C3 - Extractor de entidades** (dos vías: diccionarios y spaCy - modelo md): Actúa como componente de contextualización para la intención detectada, estructurando la consulta del usuario. Tal y como se establece en el diseño, este componente contempla dos vías alternativas para su ejecución:
 1. **Vía léxica determinista**: Utiliza diccionarios controlados organizados por categorías culinarias (ingredientes, técnicas y utensilios) para extraer las entidades mediante la intersección y coincidencia exacta de *tokens* normalizados.
 2. **Vía simbólico-semántica** (con spaCy): Utiliza el modelo mediano de spaCy para extraer todos los sustantivos y nombres propios de la consulta sin depender de un vocabulario rígido. Además, gracias a los vectores estáticos de este modelo, permite calcular la distancia semántica entre los sustantivos extraídos y los términos canónicos del dominio.
- **C4 - Motor de recuperación de FAQs** (*embeddings* + similitud coseno): Utilizando el modelo paraphrase-multilingual-MiniLM-L12-v2, este componente final recibe la intención acotada por C2 y las entidades extraídas por C3 para comparar la consulta del usuario con los embeddings precalculados de la base de datos de FAQs, recuperando la respuesta más relevante.
 1. **Vía léxica** (Whoosh + BM25): Utiliza un motor de búsqueda de texto completo para indexar y recuperar las FAQs mediante el algoritmo estadístico BM25. Es muy rápido, pero presenta limitación estructural por dependencia léxica si las palabras del usuario no coinciden exactamente con la FAQ.
 2. **Vía semántica** (*embeddings* + similitud coseno): Utiliza el modelo paraphrase-multilingual-MiniLM-L12-v2 para comparar la consulta con vectores precalculados

de las FAQs. Este enfoque es resistente a las reformulaciones y sinónimos, complementando las deficiencias del motor basado en BM25.

Como observamos en el diagrama de flujo, Consulta $\rightarrow$ T1 $\rightarrow$ {T2, T3} $\rightarrow$ T4 $\rightarrow$ Respuesta. El componente C1 precede a todos los demás permitiendo cargar los modelos preconfigurados con el idioma correcto. Superada la barrera idiomática, C2 y C3 actúan de forma independiente para estructurar la consulta (intención + entidades), y C4 utiliza esa salida estructurada para devolver la respuesta adecuada.




Figura 1: Diagrama de flujo de datos por los componentes